



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO

Trabajo Terminal

**Generador de versos musicales en el idioma
inglés por medio de procesamiento de
lenguaje natural y redes neuronales**

TT2020-B002

Presentan:

Espinosa de los Monteros Lechuga Jaime Daniel
Nava Romo Edgar Adrián
Salgado Gómez Alfredo Emilio

Directores:

Olga Kolesnikova
Ariel López Rojas

Firmas de Directores

Firmado por:

Profesor: Ariel López Rojas

Doctora Olga Kolesnikova

Índice.

Índice	2
I Trabajo Terminal I	9
1. Introducción	10
1.1. Objetivos	13
1.1.1. Objetivo general	13
1.1.2. Objetivos particulares	13
1.2. Justificación	13
1.3. Metodología	15
1.3.1. Implementación	17
1.3.2. Iteraciones	18
1.4. Organización del documento	19
2. Marco teórico	20
2.1. Inteligencia Artificial	20
2.2. Redes neuronales	21
2.2.1. Neuronas	21
2.2.2. Aprendizaje de las Redes Neuronales	23
2.2.3. Recurrent Neural Network – Long Short Term Memory	24
2.3. Procesamiento de Lenguaje Natural	26
2.3.1. Tareas del Procesamiento de Lenguaje Natural	26
2.3.2. Usos del Procesamiento de Lenguaje Natural	27
2.4. Transformers	27
2.4.1. Arquitectura de un Transformer	28
2.5. BERT	29
2.5.1. ¿Qué es Bert?	29
2.5.2. ¿Cómo funciona BERT?	29
2.5.3. BERT en la actualidad	31
2.6. GPT-2	31

2.6.1.	¿Qué es GPT-2?	31
2.6.2.	Arquitectura GPT-2	32
2.7.	BERT vs GPT-2	33
2.8.	Base de datos	34
2.8.1.	Base de datos NoSQL o no relacionales	34
2.9.	Canción	35
2.9.1.	Elementos de una canción	35
2.9.2.	Estructura de una canción	36
2.10.	Cadenas de Markov	38
2.11.	Apache	39
2.12.	Servidor Web	40
2.13.	Certificado SSL	41
2.14.	Plataforma en la Nube de Aprendizaje Automático	42
2.14.1.	Amazon Web Services	42
3.	Análisis	46
3.1.	Problemática	46
3.2.	Nuestra Solución	46
3.2.1.	¿Por qué utilizar Inteligencia Artificial?	47
3.2.2.	¿Por qué utilizar Procesamiento de Lenguaje Natural?	47
3.2.3.	¿Por qué utilizar Redes neuronales Long Short Term Memory (LSTM)?	48
3.3.	Herramientas a utilizar	48
3.3.1.	Software	48
3.3.2.	Hardware	54
3.4.	Algoritmos Utilizados	56
3.4.1.	Cadenas de Markov	56
3.4.2.	Recurrent Neural Networks	56
3.4.3.	BERT	57
3.5.	Pruebas	57
3.5.1.	Cadenas de Markov	57
3.5.2.	Pruebas con Recurrent Neural Networks	60
3.6.	Estudio de Factibilidad	61
3.6.1.	Factibilidad Técnica	61
3.6.2.	Factibilidad Operativa	64
3.6.3.	Factibilidad Económica	65
3.6.4.	Aspectos Económicos	66
3.6.5.	Aspectos Legales	67
3.7.	Análisis de riesgo	68

4. Diseño	73
4.1. Arquitectura del sistema	73
4.1.1. Descripción de la arquitectura del sistema	73
4.1.2. Funcionamiento General del Sistema	74
4.1.3. Diagrama caso de uso	76
4.1.4. Historias de Usuario	77
4.1.5. Requerimientos funcionales y no funcionales	79
4.2. Base de Datos	81
4.2.1. Descripción	81
4.2.2. Obtención de la Base de Datos	81
4.2.3. Género Musical	83
4.2.4. Resultados	84
4.3. Limpieza de la Base de Datos	85
4.3.1. Descripción	85
4.3.2. Remover caracteres innecesarios	86
4.3.3. Eliminar Duplicados	86
4.3.4. Evitar errores ortográficos o errores de similitud	86
4.3.5. Convertir los tipos de dato	86
4.3.6. Tratar los valores nulos o faltantes	86
4.3.7. Resultados	87
4.4. Modelo para Neural Network	88
4.4.1. Descripción	88
4.4.2. Herramientas usadas para generar el modelo	88
4.4.3. Modelo	88
4.4.4. Resultados	89
4.5. Generación del Modelo en la Nube	93
4.5.1. Descripción	93
4.5.2. Amazon Sagemaker	93
4.5.3. Suministrado de Datos	95
4.5.4. Resultados	96
4.6. Aplicación web	97
Anexos	100

Índice de figuras.

1.1. Funcionamiento de la planificación por cubetas	17
2.1. Estructura de una neurona [18]	22
2.2. Neurona Artificial	22
2.3. Diagrama Red Neuronal Recurrente	25
2.4. Arquitectura general de un Transformer [25]	28
2.5. Representación de entrada de BERT y la separación de la oración por palabras y la asignación de valores.[26]	30
2.6. Arquitectura del modelo de GPT-2 [31]	32
2.7. Ejemplo análisis de una oración por GPT-2 [33]	33
2.8. Diagrama de la estructura para la generación de las letras musicales	37
2.9. Diagrama de estados finitos de una cadena de Markov [37]	39
3.1. Matriz de Riesgo de Costo	69
3.2. Matriz de Riesgo de calendario	69
3.3. Matriz de Riesgo tecnológico	70
3.4. Matriz de Riesgo operacional	71
3.5. Matriz de Riesgos externos	72
3.6. Matriz General de Riesgos	72
4.1. Diagrama general del sistema	74
4.2. Diagrama de caso de uso	76
4.3. Diagrama de obtención de dataset	81
4.4. Diagrama Entidad Relación de la Base de Datos	82
4.5. Diagrama Entidad Relación de la Base de Datos	83
4.6. Diagrama Entidad Relación de las tablas Finales	84
4.7. Resultados de Limpieza de Base de Datos	87
4.8. Diagrama de diseño del modelo	89
4.9. Diagrama de diseño del modelo	90
4.10. Diseño de la estructura del modelo	92
4.11. Diagrama de instancias de AWS	93

4.12. Instancia creada en AWS	95
4.13. Diagrama del funcionamiento de SageMaker	96
4.14. Diagrama simple del proceso seguido para generar el modelo en la nube	96
4.15. Diagrama de conexión entre modelo y usuario	97
4.16. Aplicación web, pagina inicial.	98
4.17. Aplicación web, pagina una vez generada una letra musical. . .	99

Índice de cuadros.

1.1. productossimilares	12
1.2. Comparaciónmetodologíaságiles	15
2.1. BERTvsGPT-2	34
2.2. Comparación de servidores web	40
2.3. Tabla comparativa de las diversas plataformas contempladas [50]	43
2.4. Tabla comparativa GCP vs AWS (en dólares) [52]	45
3.1. Equipo de cómputo 1	54
3.2. Equipo de cómputo 2	55
3.3. Equipo de cómputo 3	55
3.4. Equipo de cómputo ideal	61
3.5. Herramientas de Software	62
3.6. Equipo de cómputo 1	62
3.7. Equipo de cómputo 2	62
3.8. Equipo de cómputo 3	63
3.9. Horas de trabajo	64
3.10. Riesgo de costo	68
3.11. Riesgo de calendario	69
3.12. Riesgo tecnológico	70
3.13. Riesgo operacional	71
3.14. Riesgos externos	71
4.1. Historia de Usuario 1	77
4.2. Historia de Usuario 2	77
4.3. Historia de Usuario 3	77
4.4. Historia de Usuario 4	77
4.5. Historia de Usuario 5	78
4.6. Historia de Usuario 6	78
4.7. Historia de Usuario 7	78
4.8. Historia de Usuario 8	78

4.9. Historia de Usuario 9	78
4.10. Historia de Usuario 10	79
4.11. Historia de Usuario 11	79
4.12. Historia de Usuario 12	79
4.13. Historia de Usuario 13	79

Parte I

Trabajo Terminal I

Capítulo 1

Introducción

La industria musical obtiene ganancias a través de la creación y divulgación de la música de manera física y digital (Bourreau and Gensollen 2006 [5]), dejando que aficionados y emprendedores de la música no tengan oportunidad de avanzar en su carrera por falta de creatividad, tiempo y/o recursos, haciendo que la creación de nuevas letras para sus canciones sea un gran obstáculo, nuestra propuesta implica la utilización de nuevas tecnologías que permitan la generación de letras para integrar con sus canciones. Esta es una de las tareas más populares y desafiantes en el área de procesamiento del lenguaje natural. Hay una gran cantidad de trabajos (Generating Text with Recurrent Neural Networks [6], Convolutional Neural Networks for Sentence Classification[7]) que proponen generar texto utilizando redes neuronales recurrentes y/o convolucionales. Sin embargo, la mayoría de los trabajos actuales solo se enfocan en generar una o varias oraciones, ni siquiera un párrafo largo y mucho menos una canción completa.

Las letras de canciones, como un tipo de texto, tienen algunas características propias, estas se constituyen de rimas, versos, coros y en algunos casos, patrones de repetición. Coro se refiere a la parte de una canción que se repite sin modificaciones dentro de la misma después de un verso, mientras que en el verso suelen cambiar una o varias líneas que lo componen. Estas características particulares hacen que generar letras musicales sea mucho más difícil que textos normales.

La mayoría de las investigaciones actuales sobre generación de letras vienen con muchas condiciones, como dar una pieza de melodía (Automatic Generation of Melodic Accompaniments for Lyrics [8]), o solo generar un tipo específico de letra (Conditional Rap Lyrics Generation with Denoising Autoencoders [9]). Sin embargo, la generación de letras por medio de in-

teligencia artificial dado un estilo y tema en particular, ha sido muy poco trabajado y debido a esto planeamos centrarnos en este nuevo problema. Estamos interesados en ver si el modelo propuesto puede aprender diferentes características de un género musical y generar letras que sean acorde a este. Actualmente, en el mercado se encuentran cuatro aplicaciones web que tienen una funcionalidad similar a la propuesta en este Trabajo Terminal:

- These lyrics do not exist.
- Bored humans - lyrics_generator.
- DeepBeat.
- Premium Lyrics.

En el cuadro 1 que se presenta a continuación, se muestran las características de aplicaciones web similares y comparándolas con nuestra propuesta:

Cuadro 1.1: Resumen de productos similares comparados con nuestra propuesta

Software	Características	Precio
These Lyrics do not Exist	Aplicación web que genera letras completamente originales de varios temas, hace uso de IA para generar coros y versos originales; se puede escoger el tema principal de la letra, género musical e incluso el estado de ánimo al que iría dirigido.	Gratuito (Contiene Anuncios)
Boredhumans lyrics_generator	Aplicación web en el que la IA fue entrenada con una base de datos con miles de letras para generar letras de canciones totalmente nuevas. La letra que crea es única y no una copia de alguna que exista actualmente, sin embargo, no permite customizar la letra.	Gratuito
DeepBeat	Aplicación web que por medio de IA genera letras de música enfocada principalmente en el género rap. Si una línea no es del agrado se puede sustituir por alguna de las otras propuestas de las que ofrece.	Gratuito
Premium Lyrics	Aplicación web que proporciona versos compuestos en distintos idiomas por artistas independientes que se escogen manualmente de acuerdo a su originalidad y calidad.	\$3 a \$75 Dólares por letra musical
Nuestra propuesta	Aplicación web que haciendo uso de una IA va a generar letras musicales originales a partir de un género musical en exclusivo, lo que asegurará un resultado original con coros y versos distintos cada vez que se utilice.	Gratuito

1.1. Objetivos

1.1.1. Objetivo general

Crear una herramienta de apoyo para estudiantes o aficionados interesados en este rubro que se les dificulte componer nuevas letras musicales de un solo género musical debido a la carencia de creatividad, la falta de conocimientos en la estructura del género o que no tengan inspiración suficiente para poder crear nuevas canciones, esto con el fin de impulsar la carrera de futuros artistas en la industria musical que no tengan los suficientes recursos para poder contratar servicios particulares de compositores.

1.1.2. Objetivos particulares

- Generar un conjunto de datos (dataset) con letras musicales de un género musical para efecto de entrenamiento de la red semántica.
- Hacer uso de alguna herramienta de aprendizaje automático (machine learning) e implementar su uso en la nube para ayudar a procesar las letras musicales de un género en específico.
- Implementar un módulo analizador de semántica para entrenar redes neuronales.
- Desarrollar una interfaz web intuitiva en versión prototipo que utilice una aplicación web alojada en la nube para la visualización del verso musical generado a partir de un género.

1.2. Justificación

El crear nuevas composiciones musicales puede llegar a ser muy difícil, estresante e incluso agotador para cualquier aficionado o incluso algunos expertos en este medio, esto se debe a la falta de creatividad y/o tiempo de quien lo quiera realizar [10]. En ocasiones se pueden contratar servicios particulares para la producción de la letra de una canción, sin embargo, puede ser muy costoso y en ocasiones el resultado final no alcanza a llenar las expectativas de la inversión que se hace; por ende, se pretende crear una herramienta para estudiantes, aficionados o cualquier persona interesada en este rubro que se les dificulte componer nuevas letras musicales.

Normalmente las letras musicales creadas por el humano, tienden a estar

compuestas por patrones de acuerdo al género musical [11]. Algunos ejemplos de estos patrones pueden ser las rimas, enunciados, frases cortas y que tengan una semántica correcta, estos pueden ser encontrados por medio de procesamiento de lenguaje natural y una investigación profunda en la composición de letras de estos géneros.

Se eligió el idioma inglés debido a que existe una gran cantidad de bases de datos para procesar, al igual que herramientas y documentación para este idioma.

Nos proponemos orientar esta solución en un entorno de nube, donde la información de configuración, servicios y datos necesarios pueden mantenerse de forma independiente a la implementación, facilitando la adaptación y flexibilidad de la plataforma.

Nuestro proyecto ayudará al usuario utilizando herramientas como el procesamiento de lenguaje natural, redes neuronales, aprendizaje de máquina (machine learning) y servidores en la nube. Se hará uso de un conjunto de datos (dataset) y herramientas alojadas en la nube (Google Cloud Platform o Amazon Web Services) para procesar estos datos; se pretende utilizar un módulo que encuentre patrones por medio de redes neuronales para analizar la semántica mediante técnicas y herramientas ya existentes de procesamiento de lenguaje natural. Se van a realizar pruebas y experimentos con estas herramientas antes de la implementación (Bert [12], spaCy[13]) para poder generar versos. A su vez se va a desarrollar una interfaz web intuitiva en versión prototipo donde el usuario va a poder utilizar esta herramienta la cual le va a mostrar la letra musical que se va a generar en ese momento.

A diferencia de los proyectos señalados en la Tabla 1.1 nuestra propuesta se va a centrar en generar letras musicales con métodos y tecnologías distintas a los que se usaron, esto es, aunque se utilicen los mismos géneros musicales se tendrán resultados completamente diferentes con propuestas distintas.

En el desarrollo de este proyecto haremos uso de los conocimientos adquiridos durante el transcurso de la carrera. Se van a utilizar técnicas de diseño de proyectos aprendidas en el curso de Ingeniería de Software, se van a aplicar los conocimientos de programación adquiridos en unidades de aprendizaje como Inteligencia Artificial, Procesamiento de Lenguaje Natural, Web Application Development, Programación Orientada a Objetos, Análisis de Algoritmos, así como técnicas de construcción de documentos y análisis de semántica vistas en Análisis y Diseño orientado a Objetos y Comunicación Oral y Escrita.

1.3. Metodología

Para el desarrollo de este trabajo terminal se utilizará la metodología ágil Scrumban, que combina algunas partes de la metodología Scrum y Kanban, debido a que este proceso de gestión reduce la complejidad al momento de desarrollar un producto el cual tratará de satisfacer las necesidades de los clientes. Además, permite trabajar colaborativamente de manera eficiente, es decir, en equipo, para obtener el mejor resultado posible.

Scrumban combina la estructura utilizada por Scrum, con los métodos basados en el flujo y visualización de Kanban. Es decir, que permite a los equipos trabajar de manera ágil usando la metodología Scrum y la simplicidad de Kanban sin tener que utilizar las actualizaciones de roles y es más sencillo de adoptar.

En la siguiente tabla se pueden observar las principales diferencias entre las tres metodologías:

Cuadro 1.2: Tabla comparativa de las distintas metodologías ágiles contempladas

	Scrum	Kanban	Scrumban
Procesos	Iterativo e incremental desarrollando sprints	Continuo	Iterativo e incremental de forma continua desarrollando iteraciones
Personas	Las personas son el centro	Las personas son el pilar	Equipo motivado con personas como pilar y en el centro
Producto	Foco en la efectividad	Foco en la eficiencia	Balance entre efectividad y eficiencia
Organización	Mejora continua del producto	Mejora continua del proceso	Mejora continua del producto y del proceso
Equipo	De 3 a 9 personas	No hay limitaciones	El equipo no requiere de un número específico de integrantes
Roles	Scrum master, Product owner, Scrum team	Pueden incluir especialistas o integrantes generalizados	No requiere un rol específico

Scrumban hace uso de iteraciones, las cuales monitorea con el apoyo de un recurso visual, como lo puede ser un tablero. Las reuniones para planificar se llevan a cabo cuando son necesarias para determinar las tareas a implementar hasta la próxima iteración. Para que estas iteraciones se mantengan cortas, se utiliza un límite de trabajo en progreso (WIP por sus siglas en inglés Work in Progress). Cuando WIP desciende de cierto nivel, se establece una acción para que el equipo sepa cuándo y qué tarea planificar a continuación.

Iteración

En Scrumban, las iteraciones son cortas para garantizar que el equipo pueda adaptarse al entorno cambiante durante el proyecto. La duración de estas iteraciones en este proyecto se medirán como máximo en lapsos de dos semanas.

Priorización

La priorización se da de tal forma que las tareas más importantes se colocan en la parte superior de la tabla de planificación seguidas por las tareas menos importantes.

Antes de llegar al tablero las tareas deben pasar por 3 etapas donde se van depurando las tareas a realizar para largo plazo (1 año), medio plazo (6 meses) y corto plazo (3 meses) siendo de esta última de donde salen las tareas más claras que se pueden completar y que ganan mayor prioridad para la próxima iteración.

Principio de Elección

Cada miembro del equipo elige qué tarea de la sección “Tareas Pendientes” va a completar a continuación.

Congelación de Funciones

Se utiliza cuando se aproxima la fecha límite del proyecto, significando que sólo pueden trabajar sobre las tareas previamente pensadas sin cabida para implementar nuevas características.

Triage

Ocurre después de la congelación de funciones, y es el punto donde el líder del proyecto decide cuáles características en desarrollo se completarán y cuáles quedarán sin terminar.




Figura 1.1: Funcionamiento de la planificación por cubetas

1.3.1. Implementación

En el proyecto se aplicará esta metodología utilizando la aplicación de Trello para llevar a cabo el tablero, contando con cuatro listas importantes:

- Scrum Backlog: Contará con las características generales de la iteración en la que se pretende trabajar.
- To Do: Lista en la que cada integrante del equipo agrega funcionalidades tanto las que son funcionales como las que no lo son que tendrá el proyecto, en sus debidas reuniones se discutirá sobre la priorización de cada una de las tarjetas que se agreguen y cada integrante elegirá las que quiera desarrollar y cuántas pueda hacer.
- In Progress: Cuando el integrante del equipo ya esta trabajando en alguna de las tareas que eligió, pasa a formar parte de esta lista, esto quiere decir que en la siguiente reunión que se tenga tendrá que dar sus debidos resultados o en su defecto, comentar que ya se terminó.
- Done: Las tareas que forman parte de la iteración que ya se terminaron, van pasando a esta lista, dejando a las otras listas con menos tarjetas

a realizar cada vez, una vez que ya estén todas las tareas realizadas, se puede volver a Backlog para poder proseguir con la siguiente iteración del proyecto, en caso de que queden tarjetas y el proyecto esté próximo a entregarse, se tendrán que parar las tareas que no sean vitales al proyecto para que se puedan realizar las tareas con más importancia.

1.3.2. Iteraciones

El proyecto se dividirá en cuatro iteraciones por proyecto terminal, cada iteración tiene una duración establecida de cuatro semanas o un mes, dejando cada iteración de la siguiente manera:

Trabajo Terminal I

- Se construirá una base de datos acorde al proyecto, la cual contendrá las letras musicales de distintos artistas, así como su género.
- Se realizará una limpieza a los datos extraídos de la base de datos.
- Se seleccionarán e implementarán las herramientas necesarias para trabajar en la construcción de un modelo para la red neuronal.
- Se integrará el modelo generado a la nube para su entrenamiento.

Trabajo Terminal II

- Se implementará la interfaz.
- Se integrará el front-end con el back-end.
- Se realizarán las pruebas pertinentes, así como la reingeniería requerida.
- Se desarrollará el manual técnico y el de usuario.

1.4. Organización del documento

Para dar inicio a este trabajo terminal, presentamos de manera breve la estructura de este reporte, con el objetivo de que el lector pueda tener un mejor entendimiento del trabajo.

Capítulo 2. Marco teórico

En esta parte del documento, se describen puntos esenciales de nuestro trabajo como definiciones, técnicas, herramientas, servicios, así como investigación realizada para llevar a cabo en la implementación dentro del trabajo.

Capítulo 3. Análisis

Dentro de este capítulo se hará un análisis tanto del problema propuesto, como sus posibles soluciones, se hará un análisis de estudio de factibilidad técnico, operativo y económico con la finalidad de conocer los recursos necesarios para la elaboración de este trabajo terminal. Se mencionan las herramientas a utilizar y se explica de manera general la arquitectura del sistema y las historias de usuario del sistema.

Capítulo 4. Diseño

En el cuarto capítulo, nos adentraremos en el desarrollo de las iteraciones propuestas, es decir, se encuentran los diagramas pertinentes para poder modelar nuestro trabajo terminal y proceder a la etapa de implementación. En este capítulo se desarrolla el diseño de cada parte del sistema y se muestra la interfaz de usuario propuesta junto con los requisitos de diseño.

Capítulo 2

Marco teórico

2.1. Inteligencia Artificial

Por Inteligencia Artificial se entiende a una simulación de procesos computacionales cognitivos para que simulen el comportamiento de una mente humana, estos comportamientos abarcan diferentes áreas de investigación, como el razonamiento, aprendizaje, percepción, comunicación y la capacidad de desarrollarse en entornos más complejos. “La inteligencia no es una dimensión única, sino un espacio profusamente estructurado de capacidades diversas para procesar la información. Del mismo modo, la Inteligencia Artificial utiliza muchas técnicas diferentes para resolver una gran variedad de tareas que se encuentran en todas partes.” [14]

En ciencias de la computación, el término de inteligencia artificial hace referencia a cualquier inteligencia semejante a la humana presentado por una computadora o un equipo electrónico. De manera popular, la inteligencia artificial hace referencia a la capacidad de una computadora o máquina de imitar las facultades del cerebro humano, es decir, que es capaz de aprender de ejemplos y experiencias, así como reconocer objetos y clasificarlos, tomar decisiones, resolver problemas, entender y responder al lenguaje, igualmente combinar estas y otras capacidades para realizar funciones similares que un ser humano podría realizar. [15]

Como objetivo, la Inteligencia Artificial pretende hacer un uso de los recursos tecnológicos para desarrollar modelos computacionales y poder resolver problemas del mundo real evolucionando constantemente.

2.2. Redes neuronales

Una red neuronal es una herramienta derivada de la inteligencia artificial que utiliza modelos matemáticos para ser utilizada como un mecanismo de predicción de texto.

Las redes neuronales son una forma de hacer que las computadoras aprendan, donde la computadora aprende a realizar alguna tarea analizando ejemplos de entrenamiento. Por lo general, estos ejemplos han sido etiquetados previamente.

Modelado vagamente en el cerebro humano, una red neuronal consiste en miles de millones de nodos de procesamiento los cuales están densamente interconectados. En la actualidad las redes neuronales están organizadas como capas de nodos, y estas capas están “alimentadas hacia adelante” (feed-forward), es decir, la información que se mueve a través de ellas solo fluye en una sola dirección. Un solo nodo puede estar conectado a muchos nodos en capas inferiores de las cuales recibe información y a su vez, puede estar conectado a nodos en capas superiores a los cuales envía información.

Cuando una red neuronal está siendo entrenada la información de entrenamiento pasa a alimentar las capas inferiores (capas de entrada), donde será procesada y pasada a capas posteriores donde será transformada hasta llegar a las capas superiores (capas de salida).[16]

2.2.1. Neuronas

Neurona Natural

La neurona es una de muchas células la cual representa a la unidad estructural y funcional del sistema nervioso. Esta trabaja transmitiendo la información a través de impulsos nerviosos o químicos, desde un lugar del cuerpo hacia otra parte de este.

Dicho impulso nervioso o impulso eléctrico viaja siempre en un mismo sentido, es decir, llega a la neurona a través de las dendritas, se procesa en el soma y posteriormente se transmite al axón, las neuronas no están en contacto entre sí, entre ellas existe un espacio de separación denominado sinapsis o espacio sináptico. Una vez que el impulso nervioso llega al extremo final del axón este libera neurotransmisores al espacio sináptico transformando esta señal eléctrica en una señal química la cual se introduce en la dendrita

de la neurona contigua, desencadenando un impulso eléctrico en la neurona receptora, repitiendo este proceso n veces hasta llegar a su destino final.[17]




Figura 2.1: Estructura de una neurona [18]

Neurona Artificial

La complejidad de las neuronas reales se abstrae mucho cuando se realiza el modelado de neuronas artificiales. Estas consisten básicamente en entradas, que se multiplican por pesos (fuerza de las respectivas señales), y luego calculada por una función matemática que determina la activación de la neurona. Otra función (que puede ser la identidad) calcula la salida de la neurona artificial (a veces en dependencia de un cierto umbral). Las redes neuronales combinan neuronas artificiales para procesar información.[19]




Figura 2.2: Neurona Artificial

2.2.2. Aprendizaje de las Redes Neuronales

Si observamos la naturaleza, podemos ver que los sistemas que pueden aprender son altamente adaptables. En su búsqueda por adquirir conocimientos, estos sistemas utilizan información del mundo exterior y modifican la información que ya han recopilado o modifican su estructura interna. Eso es exactamente lo que hacen las redes neuronales. Adaptan y modifican su arquitectura para aprender. Para ser más precisos, las redes neuronales cambian los pesos de las conexiones según la entrada y la salida deseada.

¿Por qué tienen un peso?, bueno, si observamos la estructura de las redes neuronales, hay algunos componentes que podríamos cambiar, si queremos modificar su arquitectura. Por ejemplo, podríamos crear nuevas conexiones entre neuronas, o eliminarlas, o agregar y eliminar neuronas. Incluso podríamos modificar la función de entrada o la función de activación. Resulta que cambiar los pesos es el enfoque más práctico. Además, la mayoría de los otros casos podrían cubrirse cambiando los pesos. La eliminación de una conexión, por ejemplo, se puede hacer estableciendo el peso en 0. Y una neurona se puede eliminar si establecemos los pesos de todas sus conexiones en cero.[20]

El entrenamiento es un proceso necesario para toda red neuronal, y es un proceso en el que la red se familiariza con el problema que necesita resolver. En la práctica, generalmente se tienen algunos datos recopilados en función de los cuales necesitamos crear nuestras predicciones, clasificación, o cualquier otro procesamiento. Estos datos se denominan conjunto de entrenamiento. Según el comportamiento durante el entrenamiento y la naturaleza del conjunto de entrenamiento, tenemos algunos tipos de aprendizajes:

- **Aprendizaje no supervisado:** el conjunto de entrenamiento solo contiene entradas. La red intenta identificar entradas similares y clasificarlas en ciertas categorías.
- **Aprendizaje reforzado:** el conjunto de entrenamiento contiene entradas, pero la red también recibe información adicional durante la formación. Lo que sucede es que una vez que la red calcula la salida para una de las entradas, proporcionamos información que indica si el resultado fue correcto o incorrecto y, posiblemente, la naturaleza del error que cometió la red.
- **Aprendizaje supervisado:** el conjunto de entrenamiento contiene entradas y salidas deseadas. De esta manera, la red puede verificar su

salida calculada con la salida deseada y tomar las acciones pertinentes para reformular su cálculo.

2.2.3. Recurrent Neural Network – Long Short Term Memory

Una red neuronal recurrente es un tipo de red neuronal artificial donde la salida de alguna capa en particular es salvada y sirve para retroalimentar la entrada de esta capa, lo cual ayuda a predecir futuras salidas de esta.

La primera capa esta formada de la misma manera que la Feedforward Neural Network, es decir, solo pasa la información que entra a la siguiente capa inmediata, posteriormente la siguiente capa con el paso del tiempo comenzará a retroalimentarse, pero manteniendo la propagación frontal. Haciendo uso de esta retroalimentación la capa en futuras operaciones puede realizar predicciones, si estas predicciones no son los resultados esperados, el sistema aprende y trabaja para corregir sus futuras predicciones.[21]

Se distinguen por su “memoria”, ya que toman información de entradas anteriores para influir en la entrada y salida actuales. Mientras que las redes neuronales profundas tradicionales asumen que las entradas y salidas son independientes entre sí, la salida de las redes neuronales recurrentes depende de los elementos anteriores dentro de la secuencia. Si bien los eventos futuros también serían útiles para determinar la salida de una secuencia dada, las redes neuronales recurrentes unidireccionales no pueden tener en cuenta estos eventos en sus predicciones.[22]

Estos algoritmos de aprendizaje profundo se utilizan comúnmente para problemas relacionados con la traducción de idiomas, el procesamiento del lenguaje natural, el reconocimiento de voz y los subtítulos de imágenes.

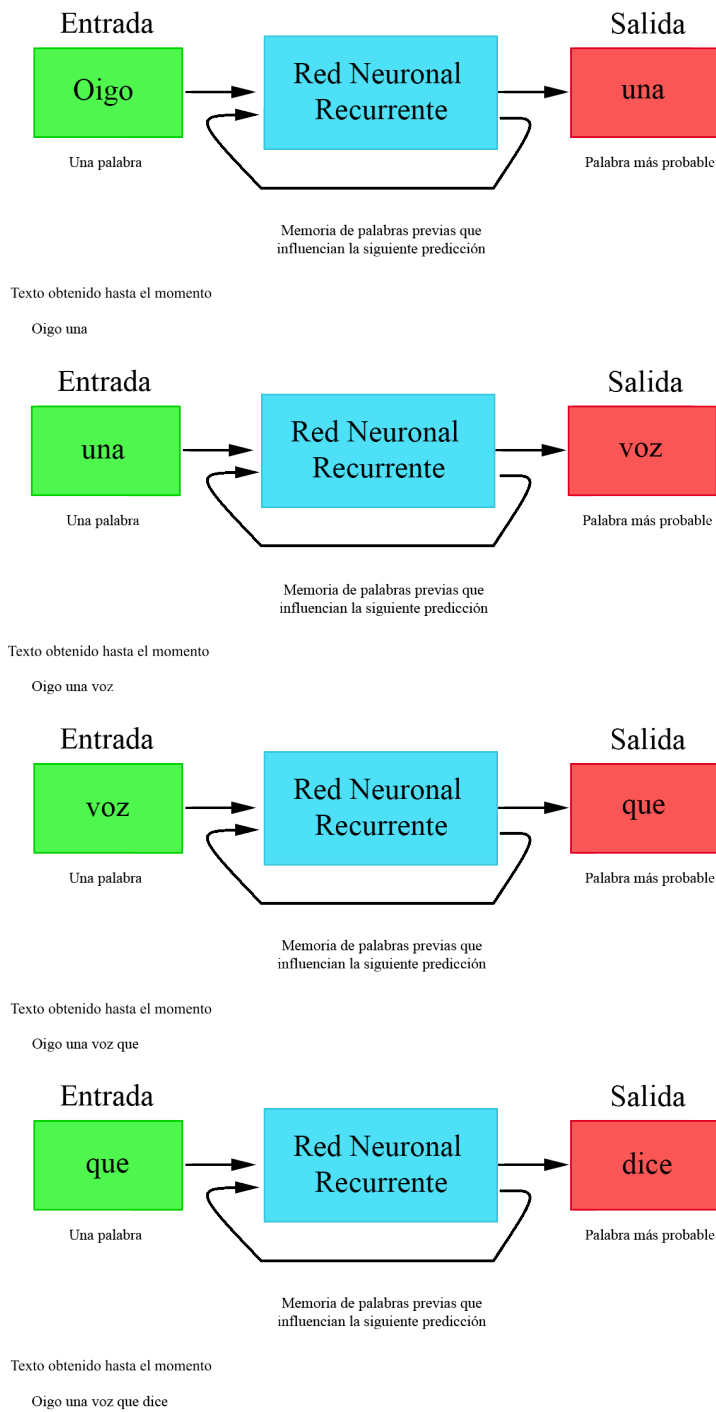


Figura 2.3: Diagrama Red Neuronal Recurrente

2.3. Procesamiento de Lenguaje Natural

El Procesamiento del Lenguaje Natural (PLN) se refiere a una rama de la informática, específicamente, a una rama de la inteligencia artificial, la cual se ocupa de dar a las computadoras la capacidad de comprender texto y palabras de la misma manera que los seres humanos.

El PLN combina la lingüística computacional con modelos estadísticos, machine learning y deep learning. Juntas, estas tecnologías permiten a las computadoras procesar el lenguaje humano en forma de texto o datos de voz y ‘comprender’ su significado completo, es decir, la intención y el sentimiento del hablante o escritor. [23]

2.3.1. Tareas del Procesamiento de Lenguaje Natural

- **Reconocimiento de voz:** La tarea pertinente al reconocimiento de voz es la conversión de la voz a texto, requiere convertir de manera confiable datos de voz en datos de texto. Lo que hace que el reconocimiento de voz sea especialmente desafiante es la forma en que las personas hablan: velocidad, arrastrando las palabras, con diferentes énfasis y entonación, así como con diferentes acentos.
- **Etiquetado de palabras:** Es el proceso de determinar la parte gramatical de una palabra o fragmento de texto en particular, en función de su uso y contexto.
- **Desambiguación de las palabras:** Es la selección del significado de una palabra con múltiples significados a través de un proceso de análisis semántico que determina la palabra que tiene más sentido en el contexto dado.
- **Reconocimiento de entidad nombrada:** Identifica palabras o frases como entidades útiles, es decir, identifica nombres propios.
- **Resolución de correferencia:** Es la tarea de identificar si dos palabras se refieren a la misma entidad. El ejemplo más común es determinar la persona u objeto al que se refiere un determinado pronombre.
- **Análisis de sentimientos:** Intenta extraer del texto cualidades subjetivas (actitudes, emociones, sarcasmo, confusión, sospecha).
- **Generación de lenguaje natural:** Es la tarea de convertir información estructurada a lenguaje humano.

2.3.2. Usos del Procesamiento de Lenguaje Natural

El procesamiento del lenguaje natural es el cerebro detrás de la inteligencia artificial en muchas aplicaciones del mundo real. Algunos ejemplos son los siguientes:

- **Aplicaciones dedicadas a la traducción:** un ejemplo de estos es Google Translate, el cual hace uso de BERT para el procesamiento del lenguaje natural así como para el etiquetado de las palabras que requiere traducir.
- **Asistentes virtuales y chatbots:** Asistentes como Siri o Alexa requieren de un reconocimiento de voz para distinguir comandos, así como para responder adecuadamente a estos. En el caso de los chatbots realizan un análisis contextual de las preguntas para proveer respuestas relacionadas a las mismas.
- **Análisis de sentimientos en redes sociales:** Consta de analizar el lenguaje utilizado en publicaciones en redes sociales, respuestas, reseñas y más para extraer actitudes y emociones en respuesta a productos, promociones y eventos; información que las empresas pueden usar en diseños de productos, campañas publicitarias y más
- **Resúmenes de textos:** Consta de realizar resúmenes y sinopsis de distintos textos.

2.4. Transformers

El Transformer en Procesamiento del Lenguaje Natural (PLN) es una arquitectura que tiene como objetivo codificar cada palabra que compone una frase en función a la secuencia que cada palabra sigue, permitiendo así agregar un contexto o una representación matemática dentro del texto.

Se suele trabajar con los transformadores en dos etapas:

- **Pre-entrenamiento:** En esta etapa, el modelo aprende cómo se estructura el lenguaje de forma general, así como de obtener un conocimiento general del significado de las palabras dentro de la frase trabajada.[24]
- **Afinado:** En esta etapa se añaden ciertas capas o funciones a la arquitectura para adaptar los modelos y que estos realicen ciertas tareas, para después estos modelos ser reentrenados y cumplan con las tareas establecidas de manera correcta.[24]

2.4.1. Arquitectura de un Transformer




Figura 2.4: Arquitectura general de un Transformer [25]

En esta arquitectura el codificador mapea una secuencia de entrada de representaciones de símbolos (x_1, \dots, x_n) a una secuencia de representaciones continuas $z = (z_1, \dots, z_n)$. Dado z , el decodificador genera una salida

secuencia (y_1, \dots, y_m) de símbolos de un elemento a la vez. En cada paso, el modelo es autorregresivo, consumiendo los símbolos generados previamente como entrada adicional para generar el siguiente.

El transformer sigue esta arquitectura general usando auto-atención, es decir, las capas están completamente conectadas tanto para el codificador como para el decodificador, que se muestran en las mitades izquierda y derecha de la Figura?? anterior, respectivamente. [25]

2.5. BERT

2.5.1. ¿Qué es Bert?

Bidirectional Encoder Representations from Transformers (BERT) es un marco de aprendizaje automático de código abierto para el Procesamiento del Lenguaje Natural (PLN). BERT, significa Representaciones de codificador bidireccional de transformers, basado en transformers, el cual es un modelo de aprendizaje profundo en el que cada elemento de salida está conectado a cada elemento de entrada y las ponderaciones entre ellos se calculan dinámicamente en función de su conexión. [26]

Al contar con la capacidad bidireccional, BERT está previamente entrenado en dos tareas de PLN diferentes, pero relacionadas: el modelado de lenguaje enmascarado y la predicción de la siguiente oración.

El objetivo del entrenamiento del Modelado de Lenguaje Enmascarado (MLM) es ocultar una palabra en una oración y luego hacer que el programa prediga qué palabra se ha ocultado en función del contexto de la palabra oculta. El objetivo del entrenamiento de predicción de la siguiente oración es que el programa prediga si dos oraciones dadas tienen una conexión lógica secuencial o si su relación es simplemente aleatoria.

2.5.2. ¿Cómo funciona BERT?

El objetivo de cualquier técnica de PLN es comprender el lenguaje humano tal como se habla de forma natural. En el caso de BERT, esto normalmente significa predecir la siguiente palabra. Para hacer esto, los modelos normalmente necesitan entrenarse usando un gran repositorio de datos de

entrenamiento especializados y etiquetados.

BERT, sin embargo, fue entrenado previamente usando solo un corpus de texto plano sin etiquetar (textos de Wikipedia en inglés). Continúa aprendiendo sin supervisión del texto sin etiquetar y mejorando incluso cuando se usa en aplicaciones prácticas. Su entrenamiento previo sirve como una capa base de “conocimiento”. A partir de ahí, BERT puede adaptarse al creciente cuerpo de contenido y consultas para ajustarse a las especificaciones del usuario. Este proceso se conoce como aprendizaje por transferencia.

BERT es posible gracias a la investigación de Google sobre transformers. El transformer es la parte del modelo que le da a BERT su mayor capacidad para comprender el contexto y la ambigüedad en el lenguaje. El transformer hace esto procesando cualquier palabra dada en relación con todas las demás palabras en una oración, en lugar de procesarlas una a la vez.




Figura 2.5: Representación de entrada de BERT y la separación de la oración por palabras y la asignación de valores.[26]

En la figura anterior, lo que se realiza es que se inserta un token [Classification (CLS)] al principio de la primera oración y un token [Separate (SEP)] al final de cada oración, cada palabra es separada en una ficha, a cada ficha se agrega una inserción que indica si se trata de la oración A o la oración B, finalmente se agrega una incrustación posicional a cada token para indicar su posición en la secuencia. [27]

Esto contrasta con el método tradicional de procesamiento del lenguaje, conocido como incrustación de palabras, en el que los modelos mapeaban cada palabra en un vector, que representa sólo una dimensión, es decir, el significado de esa palabra.

2.5.3. BERT en la actualidad

BERT se utiliza actualmente en Google para optimizar la interpretación de las búsquedas de los usuarios.

Así como en la realización de tareas tales como: [28]

- Generación de lenguaje basadas en secuencia a secuencia (Respuesta a preguntas, resúmenes de documentos, predicción de siguiente oración, chatbots).
- Comprensión del lenguaje natural (Entendimiento de la polisemia, la correferencia, la desambiguación de las palabras, clasificación de la palabras por sentimientos).

2.6. GPT-2

2.6.1. ¿Qué es GPT-2?

Generative Pretrained Transformer (GPT) es un transformer aprovechado para realizar tanto aprendizaje supervisado como aprendizaje no supervisado para el Procesamiento del Lenguaje Natural (PLN).

GPT-2 es el sucesor de GPT, es un gran modelo de lenguaje basado en transformers con 1500 millones de parámetros, entrenado en un conjunto de datos de 8 millones de páginas web. GPT-2 se entrena con un objetivo simple: predecir la siguiente palabra, dadas todas las palabras anteriores dentro de un texto. [29]

El conjunto de datos no requiere ningún paso de procesamiento previo. En otras palabras, se omiten las mayúsculas y minúsculas, la tokenización y otros pasos, ya que los autores creen que estos pasos de preprocesamiento restringen la capacidad del modelo y así ser capaz de evaluar todos los puntos de referencia del lenguaje.

Ya que en GPT-2 no se aplica una representación de las palabras ni a nivel de palabra ni a nivel de carácter. Se elige una opción que se encuentra situada en medio, que es la subpalabra. La subpalabra se puede obtener mediante el algoritmo Byte Pair Encoding (BPE).

BPE es una forma de compresión donde se calculará una lista de subpalabras utilizando el siguiente algoritmo: [30]

- Dividir palabra en secuencia de caracteres.
- Unirse al patrón de frecuencia más alta
- Continuar con el paso anterior hasta alcanzar el número máximo predefinido de subpalabras de iteraciones.

2.6.2. Arquitectura GPT-2




Figura 2.6: Arquitectura del modelo de GPT-2 [31]

El modelo de GPT-2 es un transformer decodificador de 12 capas, cada una con 12 mecanismos de atención independientes, llamados “cabezas”; el resultado es $12 \times 12 = 144$ patrones de atención distintos. Cada uno de estos patrones de atención corresponde a una propiedad lingüística capturada por el modelo. [32]

Lo que le permite identificar la relación que existe entre las palabras, entendiendo la oración y permitiendo predecir la siguiente palabra en relación a la oración.




Figura 2.7: Ejemplo análisis de una oración por GPT-2 [33]

Las líneas, leídas de izquierda a derecha, muestran dónde presta atención el modelo prediciendo la siguiente palabra en la oración (la intensidad del color representa la fuerza de la atención). Entonces, al tratar de predecir la siguiente palabra después de correr (ran), el modelo presta mucha atención al perro (dog) en este caso. Esto ya que necesita saber quién o qué está corriendo para predecir qué viene a continuación. [33]

2.7. BERT vs GPT-2

Dentro de esta sección mostramos una pequeña comparación entre las tecnologías BERT y GPT-2, visualizada en la siguiente tabla: Con base en lo anterior se determino que se va a utilizar BERT el resto del trabajo terminal para ayudarnos en la generación de los textos.

Cuadro 2.1: Comparación entre las tecnologías BERT y GPT-2

BERT	GPT-2
Es de naturaleza bidireccional.	Es de naturaleza autorregresivo.
El usuario puede entrenar sus propios modelos.	Puede resolver distintos problemas de Procesamiento del Lenguaje Natural (PLN) sin necesidad volver a entrenar la red neuronal.
La separación de palabras es manejada en tokens.	La separación de palabras es realizada por medio del algoritmo Byte Pair Encoding (BPE) generando subpalabras.
Su uso es enfocado al análisis y generación de textos.	Sus principales usos son para la generación de textos.

2.8. Base de datos

Una base de datos es un conjunto organizado de datos o información, los cuales pertenecen a un mismo contexto, se encuentran almacenados de forma física o digital con la finalidad de realizar distintas acciones como consultas futuras, ingreso de nuevos datos, actualización o eliminación de estos.

Las bases de datos se componen de una o más tablas divididas en columnas y filas y son las encargadas de guardar un conjunto de datos.

Una base de datos generalmente es manejada por un Sistema de gestión de base de datos (DBMS). En conjunto, el DBMS y los datos o información, unido a las aplicaciones asociadas a ellos, se les conoce como un sistema de base de datos.[34]

2.8.1. Base de datos NoSQL o no relacionales

Estas bases permiten que los datos no estructurados y/o semiestructurados se almacenen y manipulen, a diferencia de la base de datos relacional donde se define como deben de componerse todos los datos insertados en esta. Generalmente los registros de este tipo de base de datos suelen almacenarse como un documento de tipo JSON.

2.9. Canción

Una canción es una composición literaria, generalmente escrita en versos, a la cual se le puede acompañar con música para poder ser cantada.[35]

2.9.1. Elementos de una canción

Los elementos que conforman una canción son los siguientes:

Introducción

Generalmente es una parte única la cual se encuentra al inicio de una canción, acompañada de una armonía o melodía compuesta solo para este inicio. El objetivo de la introducción es de atraer la atención y producir un ambiente.[36]

Verso

Es la parte encargada de comenzar a desarrollar la idea a transmitir, trata de contarnos el tema de la canción, y ya cuenta con una armonía bien establecida.

Pre-coro

Es un arreglo que permite realizar una transición, su función principal es conectar el verso con el coro. También ayuda a evitar que el coro se estanque en la monotonía.

Coro

Es una estrofa la cual se repite varias veces dentro de una composición. Su función principal es acentuar la idea principal de la canción tanto en su letra como en lo musical. Se considera como una de las partes más importantes dentro de una canción y en algunas ocasiones este es repetido al inicio y al final.

Puente

Es un interludio el cual conecta dos fragmentos de una canción, permitiendo construir una armonía entre ellas, suele ser usado para llevar a la canción a su clímax, para prepararlo para el desarrollo final de la canción.

Cierre

Este busca terminar o concluir una canción, una de las formas puede ser un ruptura brusca generada por un silencio imprevisto o por una secuencia de acordes. Pero la manera más ordinaria de cerrar es haciendo uso de la repetición de un coro.

2.9.2. Estructura de una canción

La estructura mínima de una canción está compuesta de:

- Verso
- Coro
- Verso
- Coro

La estructura más empleada en una canción es la siguiente:

- Introducción
- Verso
- Pre-coro
- Coro
- Verso
- Coro
- Puente
- Cierre

Se pretende trabajar la estructura de la generación de letras musicales de la siguiente forma:

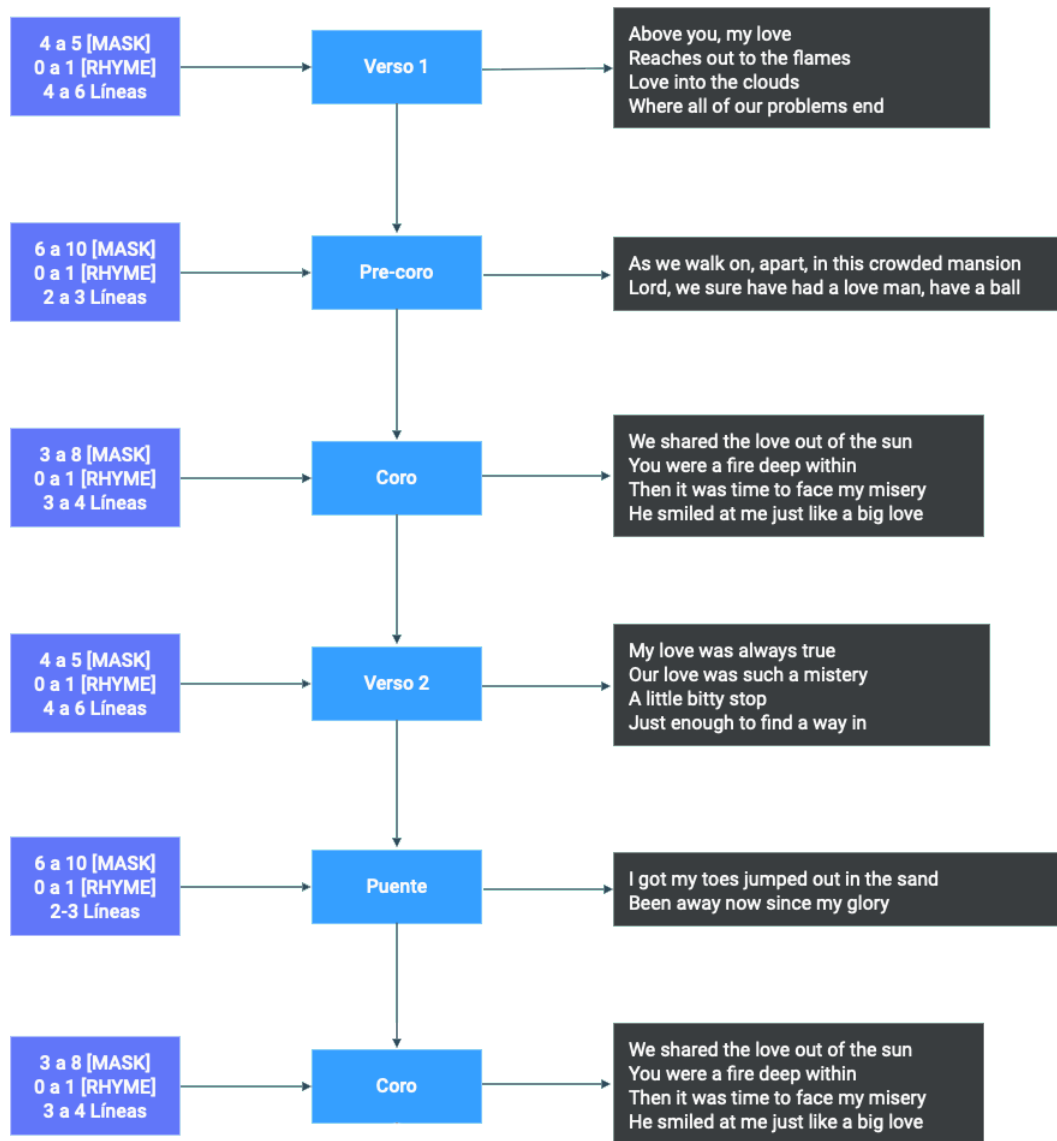


Figura 2.8: Diagrama de la estructura para la generación de las letras musicales

2.10. Cadenas de Markov

Las cadenas de Markov son un sistema matemático el cual experimenta con las transiciones de un estado a otro de acuerdo con ciertas reglas probabilísticas. La característica que define a una cadena de Markov es que no importa cómo llegó el proceso a su estado actual, y sus posibles estados futuros son fijos. En otras palabras, la probabilidad de pasar a cualquier otro estado depende únicamente del estado actual y del tiempo transcurrido. El espacio de estados o conjunto de todos los posibles estados, pueden ser cualquier cosa: letras, números, puntuaciones de un partido, acciones, etc.

Son procesos estocásticos, con la diferencia de que estos deben ser “sin memoria”, es decir, la probabilidad de las acciones futuras no depende ni se ve afectada de los pasos que la condujeron al estado actual. A esto se le denomina una propiedad de Markov.

En la teoría de probabilidad, el ejemplo más inmediato es el de una cadena de Markov homogénea en el tiempo, en la que la probabilidad de que ocurra cualquier transición de estado es independiente del tiempo.

En el lenguaje de probabilidad condicional y variables aleatorias, una cadena de Markov es una secuencia X_0, X_1, X_2, \dots de variables aleatorias que satisfacen la regla de independencia condicional. En otras palabras, el conocimiento del estado anterior es todo lo que se necesita para determinar la distribución de probabilidad del estado actual. Esta definición es más amplia que la explorada anteriormente, ya que permite probabilidades de transición no estacionarias y, por lo tanto, cadenas de Markov no homogéneas en el tiempo; es decir, a medida que pasa el tiempo los pasos aumentan y la probabilidad de pasar de un estado a otro puede cambiar. [37]

Las cadenas de Markov pueden ser modeladas mediante máquinas de estados finitos.




Figura 2.9: Diagrama de estados finitos de una cadena de Markov [37]

2.11. Apache

Es un servidor web gratuito y de código abierto el cual permite que los desarrolladores de sitios web puedan desplegar el contenido de ellas, este no es un servidor que se encuentre físicamente, sino que se trata de un software el cual ejecuta un servidor. Su función es instaurar la conexión entre un servidor y los usuarios del sitio web mientras estos intercambian archivos entre ellos (siguiendo una estructura cliente-servidor). El servidor y el cliente interactúan mediante el protocolo HTTP, y el software de Apache es el encargado de mantener una comunicación ágil y segura entre las 2 partes.[44]

Apache trabaja sin problemas con otros sistemas de gestión de contenido (Drupal, Joomla, etc.), marcos de trabajo (Django, Laravel, etc.), y lenguajes de programación. Por estas razones se vuelve una opción sólida al momento de escoger entre los distintos tipos de plataformas de alojamiento web, como serían Virtual Private Server (VPS) o alojamiento compartido.[45]

Cuadro 2.2: Tabla comparativa de los distintos servidores web contemplados para nuestro proyecto

Apache	NGINX [38]
Es fácil de configurar, cuenta con muchos módulos, así como un entorno sencillo.	Usa hilos para manejar solicitudes del usuario.
De código abierto y gratuito, inclusive si se usa de manera comercial.	Nginx es uno de los servidores web que soluciona el problema c10k y seguramente de los más exitoso al hacerlo.
Software estable y confiable.	No crea un nuevo proceso por cada solicitud.
Frecuentemente actualizado incluyendo actualizaciones regulares a los parches de seguridad.	Maneja toda solicitud entrante en un único hilo.
Funciona de forma intuitiva, con sitios web hechos con WordPress.	El modelo basado en eventos de Nginx reparte las solicitudes de los usuarios entre procesos de trabajo de manera eficiente.
Comunidad grande y posibilidad de contactar con soporte disponible de manera sencilla en caso de cualquier problema.	Cuenta con mejor escalabilidad.
Presenta inconvenientes de rendimiento con sitios web los cuales tienen alto tráfico.	Es capaz de manejar un sitio web con demasiado tráfico con un uso de recursos mínimo.
Al contar con muchas preferencias de configuración puede generar vulnerabilidades de seguridad.	

En ambos casos, se mantienen en desarrollo, con actualizaciones constantes, así como frecuentemente sacando parches para evitar ataques de DDos.

2.12. Servidor Web

La función es mostrar sitios web en internet. A fin de conseguir este objetivo, actúa como un mediador entre el servidor y el dispositivo del cliente. Obtiene el contenido del servidor en cada petición hecha por el usuario y lo entrega al sitio web.[46]

Los servidores web son capaces de procesar archivos escritos en distintos lenguajes de programación como Java, PHP, Python, y otros.

Podría decirse que un servidor web es la herramienta responsable por la correcta comunicación entre el cliente y el servidor.

2.13. Certificado SSL

Conocido como Secure Socket Layer (SSL) o (Capa de Conexión Segura) es un estándar de seguridad global que fue originalmente creado por Netscape en los 90's. SSL crea una conexión encriptada entre tu servidor web y el navegador web de tu visitante permitiendo que la información privada sea transmitida sin que ocurran problemas como serían espionaje, manipulación de la información, y falsificación de los datos del mensaje.[47] Básicamente, la capa SSL permite que dos partes tengan una “conversación” privada.

Para establecer esta conexión segura, se instala en un servidor web un certificado SSL (también llamado ‘certificado digital’) que cumple dos funciones:

- Autenticar la identidad del sitio web, garantizando a los visitantes que no están en un sitio falso.
- Cifrar la información transmitida.

Hay varios tipos de certificados SSL [48] según la cantidad de nombres de dominio o subdominios que se tengan, como por ejemplo:

- Único: Asegura un nombre de dominio o subdominio completo (Fully Qualified Domain Name (FQDN) por sus siglas en inglés).
- Comodín: Cubre un nombre de dominio y un número ilimitado de sus subdominios.
- Multidominio: Asegura varios nombres de dominio.

2.14. Plataforma en la Nube de Aprendizaje Automático

El entrenamiento de aprendizaje automático y de modelos de aprendizaje profundo involucra miles de iteraciones. Se necesitan esta gran cantidad de iteraciones para producir el modelo más preciso.

El cómputo en la nube permite modelar capacidad de almacenamiento y manejar cargas a escala [49], o escalar el procesamiento a través de los nodos. Por ejemplo, AWS ofrece instancias de GPUs con capacidad de memoria que va de los 8Gb's a los 256Gb's, estas instancias son cobradas a ritmos por hora.

Las GPUs son procesadores especializados diseñados para procesado complejo de imágenes. Azure de Microsoft ofrece GPUs de alto rendimiento de la serie NC para aplicaciones o algoritmos de cómputo de alto rendimiento.

2.14.1. Amazon Web Services

Dentro de las bondades que ofrecen los Servicios Web de Amazon (Amazon Web Services (AWS) por sus siglas en inglés) y que nos pueden ser de utilidad para las necesidades de nuestro proyecto se pueden encontrar:

- **SageMaker:** Es una plataforma de aprendizaje automático completamente administrado para científicos de datos y desarrolladores. La plataforma corre en Cómputo Elástico en la Nube (Elastic Compute Cloud (EC2) por sus siglas en inglés), y permite construir modelos de aprendizaje automático, organizar la información y escalar sus operaciones.

Algunas aplicaciones de aprendizaje automático en SageMaker van desde reconocimiento de voz hasta visión de computadora, e incluso recomendaciones basadas en el comportamiento aprendido del usuario.

El mercado de AWS ofrece modelos que se pueden usar en lugar de empezar desde cero, posterior a eso se puede entonces empezar a entrenar y optimizar el modelo; las elecciones más comunes son frameworks como Keras, TensorFlow, y PyTorch; Sagemaker puede optimizar y configurar estos frameworks automáticamente, o pueden ser entrenadas de manera personal.

Uno mismo puede incluso desarrollar su propio algoritmo construyéndolo en un contenedor de Docker o se puede hacer uso de una “Jupyter notebook” [51] para construir un modelo propio de aprendizaje automático y visualizar su información usada para el entrenamiento del modelo siendo este punto lo que más nos interesa para nuestro proyecto.

Cuadro 2.3: Tabla comparativa de las diversas plataformas contempladas [50]

Característica	GCP [68]	AWS [69]	Azure [70]
Jupyter Notebook alojado de manera local o remota	Plataforma de IA	SageMaker Studio IDE	- Estudio de Notebooks de Azure de Aprendizaje Automático - Databrick de Azure
Entrenamiento Distribuido	Si	Si	Si
Versionado de Modelos	Si	Si	Si
Seguimiento de Experimentos	Si	Si	Si
AutoML (UI y API)	Tabla de AutoML	Autopiloto de SageMaker	AutoML
Análisis de Errores	Tabla de AutoML con BigQuery	Debugger de SageMaker	Aprendizaje Profundo de Azure

Los tres proveedores de la tabla anterior han alojado servicios de “Jupyter Notebook” (contienen tanto código de computadora como elementos ricos en texto como ecuaciones, figuras, etc.), experimentando seguimientos y control de versiones, y métodos de despliegue sencillos.

Dentro de las características únicas de cada una de las plataformas podemos encontrar que la Plataforma de la Nube de Google (GCP) usa un paquete llamado “what if tool” el cual se puede integrar junto a un “Jupyter Notebook” y de esa manera jugar con el modelo cambiando el umbral o un valor característico de un ejemplo dado, esto permite checar como es que ciertos cambios afectan el resultado predicho con anterioridad previo al cambio.

El debugger de SageMaker de AWS permite analizar cómo es que la ingeniería de características y el refinado del modelo son hechos, o de forma más concisa, permite ver qué sucede durante el entrenamiento del modelo.

Azure, por su parte, provee un módulo propio en su SDK el cual parece tener la mejor integración de entre las tres plataformas.

Costo y Rendimiento del Modelo

Azure y GCP puntúan ligeramente mejor que AWS en términos de rendimiento, esto no necesariamente significa que una plataforma es mejor que otra.

El costo de AWS fue considerablemente menor que GCP y Azure. Por supuesto, cada una tiene sus fuertes como puede verse en la tabla presentada anteriormente.

El diseñador de aprendizaje automático de Azure cuenta con una interfaz de arrastrar y soltar el cual es bastante amigable con un usuario novato, esto es, porque requiere menos codeo y antecedentes técnicos. AWS y GCP parecen ser más enfocados a desarrolladores aunque puede resultar en más de trabajo ensamblar una cadena de procesos (pipeline), estos resultan más personalizables con los diferentes componentes disponibles. Estos componentes y la conexión de la cadena de procesos son usualmente desarrollados usando código y configuraciones, en vez de utilizar una interfaz.

Tanto GCP como AWS ofrecen un modelo de pago “pay-as-you-go”. Este modelo es el mejor para aquellos individuos que puedan llegar a esperar un uso intermitente de la nube, ya que permite un enfoque flexible para añadir y

remover servicios cuando se necesite. Por supuesto, este nivel de flexibilidad tiene un costo, haciendo al modelo “pay-as-you-go” el más caro por hora.

Cuadro 2.4: Tabla comparativa GCP vs AWS (en dólares) [52]

Tipo de Instancia	Precio de EC2 (por hora)	Precio de Google (por hora)
Propósito General	\$0.134	\$0.15
Cómputo Optimizado	\$0.136	\$0.188
Optimizado de Memoria	\$0.201	\$0.295
GPU	\$0.526	\$1.4

En conclusión, la opción ideal para las necesidades de nuestro proyecto es AWS debido a que es más económico que las otras dos plataformas y cuenta con herramientas más útiles como SageMaker que nos permitirá saber cómo se está entrenando el modelo.

Capítulo 3

Análisis

3.1. Problemática

Los nuevos artistas musicales suelen frustrarse durante el proceso creativo para la composición de una letra musical, debido a que no cuentan con la creatividad o el tiempo para realizarlas, además de que esta tarea puede ser agotadora, difícil y estresante, en consecuencia, pueden llegar a abandonar sus sueños y aspiraciones.

Estos artistas pueden contar con ciertos servicios los cuales ofrecen letras de canciones, pero estas suelen estar precios muy altos o estas no cumplen con las expectativas de los artistas al invertir en ellas.

3.2. Nuestra Solución

Debido a lo anterior se ha decidido desarrollar una herramienta de apoyo para estudiantes o aficionados interesados, a los cuales se les dificulte componer nuevas letras musicales, con la finalidad de impulsar la carrera de futuros artistas en la industria musical que no cuenten con los recursos suficientes para poder contratar servicios particulares de compositores.

Dicha herramienta de apoyo se realizará con ayuda de la inteligencia artificial, así como de un modelo de red neuronal recurrente para la generación de las nuevas letras musicales, los usuarios de esta herramienta podrán interactuar con la herramienta para generar letras personalizadas según sus propuestas dadas.

Para corroborar que sea la mejor opción, se implementarán pruebas con otras

herramientas como BERT y Cadenas de Markov con las que podremos comparar el resultado.

3.2.1. ¿Por qué utilizar Inteligencia Artificial?

Se eligió la inteligencia artificial como tecnología principal para desarrollar este sistema, se quiere investigar el funcionamiento de las redes neuronales y su impacto que puede llegar a tener en el área de la creatividad y generación de texto, que es un campo relativamente nuevo y con muchos alcances que aún quedan por descubrir.

Cabe destacar que aunque es un tema relacionado con la ingeniería en sistemas computacionales, no es algo que se aprenda como tema principal, por lo que requerirá una ardua investigación y desarrollo para poder lograr los objetivos propuestos.

La inteligencia artificial nos permite buscar patrones y al mismo tiempo soluciones nuevas y eficientes, para problemas que antes no se podía saber que una computadora podría hacer.

3.2.2. ¿Por qué utilizar Procesamiento de Lenguaje Natural?

El Procesamiento de Lenguaje Natural, es una rama de la inteligencia artificial que es estudiada desde 1940-1950[81] y ha tenido avances que han podido ayudar a diferentes áreas tales como:

- Analisis de Sentimientos
- Clasificación de Texto
- Chatbots & Asistentes Virtuales
- Extracción de texto
- Traductores
- Auto correctores. Y en estos últimos años gracias al hardware que se tiene hoy en día, es posible tener avances en la generación de texto.

3.2.3. ¿Por qué utilizar Redes neuronales Long Short Term Memory (LSTM)?

Se hará uso de este tipo de redes neuronales debido a que se ha visto que destacan para la generación de texto [78], sobre todo de textos que requieren de contexto, esto es, que las palabras previamente escritas servirán para la inferencia de las posibles palabras futuras. Otros tipos de redes neuronales como las convolucionales o las de multicasas se enfocan en trabajar las palabras de una en una como van llegando sin tomar en cuenta el contexto o sentido dado por las palabras previas, dando poca o nula coherencia al texto generado por estas.

En especial se pretende trabajar con las redes recurrentes de tipo LSTM debido a que estas pueden “recordar” estados previos y utilizar la información originada de esos estados previos para así poder generar con mayor eficiencia el resultado siguiente, la cual es una característica que no tiene una red neuronal recurrente estándar que en general solo se retroalimenta de un estado pasado o una GRU (Gated Recurrent Unit) la cual en términos generales tiene dos puertas las cuales controlan que información debe mantenerse en memoria así como que información debe de entrar para reajustar el modelo y la salida a generar.

3.3. Herramientas a utilizar

3.3.1. Software

Para el desarrollo de software de este prototipo, es necesario hacer mención de algunas de las siguientes herramientas y lenguajes de programación, para tener una idea clara sobre qué herramientas estamos utilizando y porque es que las estamos utilizando:

Python

Python es un lenguaje de programación orientado a objetos y de alto nivel con semántica dinámica. Sus estructuras de datos integradas de alto nivel, combinadas con tipado dinámico y enlace dinámico, lo hacen muy atractivo para el desarrollo rápido de aplicaciones, así como para su uso en scripts o para conectar componentes ya existentes. La sintaxis simple y fácil de aprender de Python enfatiza la legibilidad y, por lo tanto, reduce el costo de mantenimiento del programa. Python admite módulos y paquetes, lo que fomenta la modularidad del programa y la reutilización del código.[57]

Las principales ventajas de Python son:

- Es fácil y rápido desarrollar una aplicación.
- Cuenta con una gran cantidad de librerías.
- Es fácil de entender el código y darle mantenimiento.

Principales desventajas son:

- En ocasiones la ejecución del código es lenta.
- Consume mucha memoria.

BERT

Bidirectional Encoder Representations from Transformers (BERT) es un marco de aprendizaje automático de código abierto para el Procesamiento del Lenguaje Natural (PLN). BERT, significa Representaciones de codificador bidireccional de transformers, basado en transformers, el cual es un modelo de aprendizaje profundo en el que cada elemento de salida está conectado a cada elemento de entrada y las ponderaciones entre ellos se calculan dinámicamente en función de su conexión. [26]

Al contar con la capacidad bidireccional, BERT está previamente entrenado en dos tareas de PLN diferentes, pero relacionadas: el modelado de lenguaje enmascarado y la predicción de la siguiente oración.

El objetivo del entrenamiento del Modelado de Lenguaje Enmascarado (MLM) es ocultar una palabra en una oración y luego hacer que el programa prediga qué palabra se ha ocultado en función del contexto de la palabra oculta. El objetivo del entrenamiento de predicción de la siguiente oración es que el programa prediga si dos oraciones dadas tienen una conexión lógica secuencial o si su relación es simplemente aleatoria.

HTML

Hypertext Markup Language (HTML) es un lenguaje de marcado que define la estructura de una página web y su contenido. HTML consta de una serie de elementos que se utilizan para encerrar o envolver diferentes partes del contenido para que estos se visualicen de cierta manera o actúe de cierta manera. Las etiquetas adjuntas pueden hacer que una palabra o imagen sea un hipervínculo a otro lugar, pueden poner palabras en cursiva, pueden hacer

que la fuente sea más grande o pequeña, etc. [39]

HTML5 es la versión mas reciente de html, la cual integra nuevos elementos, atributos y comportamientos. Permite describir de mejor manera el contenido de la página web, así como mejora su conectividad con el servidor y almacenamiento, posibilita que las paginas web puedan operar sin conexión usando los datos almacenados localmente del lado del cliente, otorga un mejor soporte al contenido multimedia así como una mejor integración a APIs y un mejor diseño usando CSS3. [40]

CSS

Cascading Style Sheet (CSS) es el lenguaje para describir la presentación de las páginas web así como hacerlas más atractivas. Permite adaptar la presentación a diferentes tipos de dispositivos. CSS es independiente de HTML y puede ser empleado con cualquier otro lenguaje de marcado basado en XML o SVG. Usando CSS se pueden controlar con precisión cómo se ven los elementos HTML en el navegador, que presentará para las etiquetas de marcado el diseño que cada uno desee. La separación de HTML de CSS facilita el mantenimiento de los sitios, compartir las hojas de estilo entre páginas y adaptarlas a distintos ámbitos. [41]

Es un lenguaje basado en reglas: cada usuario define las reglas que especifican los grupos de estilos que van a aplicarse a elementos particulares o grupos de elementos de la página web.

Antes de CSS, las etiquetas como fuente, color, estilo de fondo, alineación, borde y tamaño tenían que repetirse en cada elemento de una página web. Ahora con los CSS, podemos definir cómo se van a comportar las etiquetas, al ser guardado en un archivo por separado, esta misma configuración puede usarse en otra página web ahorrando tiempo diseñándola. Además de que CSS provee de mejor y más detallados atributos para cada etiqueta.

JavaScript

JavaScript es un lenguaje de programación o secuencias de comandos que permite implementar funciones complejas en las páginas web. Estos scripts pueden ser desarrollados en el mismo HTML para que sean ejecutados automáticamente cuando se carga dicha páginas web, estos scripts se proporcionan y ejecutan como texto sin formato. No necesitan una preparación especial ni una compilación para ejecutarse. [42]

JavaScript puede ejecutarse no solo en un navegador, sino también en un servidor, o en cualquier dispositivo que tenga un programa especial llamado JavaScript engine, el cual permite interpretar y ejecutar los scripts.

JavaScript permite crear contenido dinámico dentro de las páginas web, reaccionar ante algunas acciones realizadas por los usuarios como lo son los clicks del ratón, el movimiento del puntero o el presionar cierta tecla, permite enviar peticiones al servidor, así como descargar y subir archivos, además es posible obtener y configurar cookies, mostrar mensajes o alertas al usuario.

OpenSSL

Consiste en un paquete robusto de herramientas de administración y bibliotecas las cuales están relacionadas con la criptografía, estas suministran funciones criptográficas a otros paquetes como OpenSSH y navegadores web (permitiendo un acceso seguro a sitios HTTPS) [59]. Estas herramientas contribuyen al sistema a instaurar el protocolo Secure Socket Layer (SSL), de igual manera como otros protocolos relacionados con la seguridad, como el Transport Layer Security (TLS). OpenSSL posibilita la creación certificados digitales los cuales pueden aplicarse a un servidor, por ejemplo a Apache [43].

MongoDB

MongoDB es un sistema de base de datos multiplataforma dirigido a documentos, de esquema libre, es decir, que cada registro o entrada es capaz de contar con un esquema de datos distinto, con columnas o atributos que pueden variar o no de un registro a otro.

Sus características más destacadas son su sencillo sistema de consulta de la base de datos y la velocidad. Alcanzando así un balance perfecto entre rendimiento y funcionalidad. MongoDB utiliza un modelo NoSQL el cual es un modelo de agregación que se basan en la noción de agregado, entendiendo el agregado como una colección de objetos relacionados que se desean tratar de forma semántica e independiente [58].

Las ventajas que ofrece MongoDB como herramienta de desarrollo de base de datos no relacionales son:

- La base de datos no tiene un esquema de datos predefinido.
- El esquema puede variar para instancias de datos que pertenecen a una misma entidad.
- En ocasiones el gestor de la base de datos no es consciente del esquema de la base de datos.

- Permite reducir los problemas de concordancia entre estructuras de datos usadas por las aplicaciones y la base de datos.
- Frecuentemente se aplican técnicas de desnormalización de los datos.

Amazon EC2

Amazon Elastic Compute Cloud (EC2) [82] proporciona una infraestructura de tecnologías de información que se ejecuta en la nube y funciona como un centro de datos que se ejecuta en su propia sede. Es ideal para empresas que necesitan rendimiento, flexibilidad y potencia al mismo tiempo.

Amazon EC2 es un servicio que permite alquilar un servidor o máquina virtual de forma remota para ejecutar aplicaciones. Las principales ventajas de Amazon EC2 son:

- Cuenta con plantillas predeterminadas de máquinas virtuales y servidores.
- Permite configurar la memoria, almacenamiento, CPU y otras características dependiendo las necesidades del usuario.
- Precios dependiendo del uso y características del equipo o servidor alquilado.

Las principales desventajas son:

- Tiene una curva de aprendizaje alta para los nuevos usuarios.
- Los costos de soporte técnico son muy elevados.

Amazon SageMaker

Amazon SageMaker [83] es un servicio que ayuda a científicos y desarrolladores a construir, entrenar e implementar de manera rápida y sencilla modelos de machine learning.

Para construir el modelo, este servicio cuenta con algoritmos de machine learning más utilizados que vienen preinstalados. También está preconfigurado para que pueda ejecutar Apache MXNet y TensorFlow.

Para el entrenamiento, con un solo clic en la consola de servicio, es fácil comenzar a entrenar su modelo. Amazon SageMaker se encarga de cada infraestructura y facilita la escalabilidad lo que permite entrenar los modelos a

escala de petabytes. Si se desea acelerar y simplificar el proceso de entrenamiento, se puede ajustar automáticamente el modelo para obtener la mejor precisión.

Para desplegar el modelo entrenado, el modelo se aloja en un clúster de escalado automático de Amazon EC2.

Amazon S3

Amazon Simple Storage Service (S3) [84], como su nombre lo indica, es un servicio web proporcionado por Amazon Web Services (AWS) que proporciona almacenamiento. Este almacenamiento es altamente escalable en la nube.

Apache

Es un servidor web gratuito y de código abierto el cual permite que los desarrolladores de sitios web puedan desplegar el contenido de ellas, este no es un servidor que se encuentre físicamente, sino que se trata de un software el cual ejecuta un servidor [60]. Su función es instaurar la conexión entre un servidor y los usuarios del sitio web mientras estos intercambian archivos entre ellos (siguiendo una estructura cliente-servidor). El servidor y el cliente interactúan mediante el protocolo HTTP, y el software de Apache es el encargado de mantener una comunicación ágil y segura entre las 2 partes.

Apache trabaja sin problemas con otros sistemas de gestión de contenido (Drupal, Joomla, etc.), marcos de trabajo (Django, Laravel, etc.), y lenguajes de programación. Por estas razones se vuelve una opción sólida al momento de escoger entre los distintos tipos de plataformas de alojamiento web, como serían Virtual Private Server (VPS) o alojamiento compartido.

3.3.2. Hardware

Se usarán los equipos de cómputo con los que los integrantes del equipo contamos actualmente, los cuales se especifican a continuación:

Cuadro 3.1: Equipo de cómputo 1

Equipo de cómputo utilizado. [1]	
Procesador	Ryzen 5 3600
Tarjeta de video	Amd Radeon Rx580
Memoria RAM	32 Gb
Disco duro	1Tb HDD y 512Gb SSD

Cuadro 3.2: Equipo de cómputo 2

Equipo de cómputo utilizado. [2]	
Marca	Apple
Modelo	iMac Late 2012
Procesador	Intel Core i5
Tarjeta de video	NVIDIA GeForce GT 640M 512 Mb
Memoria RAM	8 Gb
Disco duro	1Tb y 256 Gb SSD

Cuadro 3.3: Equipo de cómputo 3

Equipo de cómputo utilizado. [3]	
Procesador	Amd FX-8350
Tarjeta de video	Nvidia Geforce 1050ti
Memoria RAM	16 Gb
Disco duro	1Tb HDD

3.4. Algoritmos Utilizados

La Inteligencia Artificial es un campo emergente donde se desarrollan nuevas aplicaciones de innovación continuamente. Para este generador de letras musicales será necesario implementar diferentes estrategias para poder evaluar cuál es la mejor opción, para ello, se utilizarán tres recursos importantes para ver la evolución de las pruebas y poder evaluar el resultado óptimo a nuestras posibilidades para poder implementarlo en este proyecto.

3.4.1. Cadenas de Markov

Este sería el algoritmo más sencillo a utilizar, consiste en generar texto de acuerdo a otro texto previo, sin embargo funciona de manera mecánica dando valores aleatorios para generar un texto, posiblemente los enunciados que se generan tienen una estructura medianamente correcta, sin embargo el sentido que tendrá el texto no tendrá ningún sentido, se hará esta prueba para ver el alcance que se tiene con este tipo de algoritmo y poder comparar los resultados finales del proyecto.

3.4.2. Recurrent Neural Networks

Anteriormente se explicó lo que eran las redes neuronales recurrentes, en el algoritmo, se aplica para predecir palabras dependiendo de los datos anteriores, a esto se le llaman datos secuenciales, debido a que este algoritmo recuerda la entrada debido a su memoria interna.

Centrándonos en la generación de nuevas letras musicales, si observamos atentamente el uso de este tipo de redes neuronales, los datos serán secuenciales ya que las letras de las canciones dependen una de otra. Por lo tanto se usarán redes neuronales del tipo Long Short Term Memory (LSTM) de Recurrent Neural Network (RNN).

Este tipo de redes neuronales son una extensión de Recurrent Neural Network (RNN) que ayuda a recordar, en el siguiente diagrama se muestran los componentes de una red neuronal de este tipo:

- Estado de la celda
- Olvida la puerta
- Puerta de entrada
- Puerta de salida

- Memoria celular actual
- Salida de celda actual

Los resultados de este tipo de redes neuronales puede variar según el dataset que se utiliza y si la limpieza se hizo correctamente, de igual forma importa mucho el hardware utilizado para que el tiempo de generación del modelo no sea tardado y no consuma más de lo que tiene la computadora.

3.4.3. BERT

Como última opción de algoritmo, se utilizará BERT para generar nuevo texto, a través de las llamadas mascarar y separadores, es posible crear nuevas oraciones, sin embargo si se usa esta herramienta, es necesaria la implementación de otro tipo de herramientas, ya que al ser bidireccional, la generación de texto no saldrá si no se ingresa algún texto previamente.

La idea es utilizar una API que genere palabras que rimen y que genere cierta cantidad de rimas que sirvan como texto previo para que BERT pueda generar algún texto sin ningún problema.

3.5. Pruebas

3.5.1. Cadenas de Markov

Una de las primeras pruebas que se realizó durante el desarrollo del proyecto fue la generación de textos utilizando cadenas de Markov. Se ingresará el dataset limpio y organizado y este realizará un cálculo y la asignación de los valores, las oraciones y las palabras que aparecen dentro de estas. Los valores asignados variarán entre los decimales de 0 y 1 sin llegar a ser enteros nunca, estos son asignados dependiendo a la frecuencia en la que la palabra va apareciendo.

Una vez asignadas, es posible determinar si la generación del texto se desea pseudo-aleatoria o utilizar valores que cumplan ciertas condiciones como generar textos arriba o abajo de 0.5 o el tamaño del texto generado.

Para esta prueba se decidió no influir en la selección de palabras por sus valores, dejando este atributo pseudo-aleatorio, sin embargo para no generar textos de tamaños diferentes, los parámetros de las palabras fueron manipulados para que cada oración diera un determinado número, esto para evitar

que los versos fuesen de un tamaño no deseado.

A continuación un ejemplo de los resultados obtenidos:

```
1 Verse 1
2 It's where I am cannibal.
3 My first love broke my heart was stolen.
4 But you rather be!. Every moment, everything can change your
   life, I'mma change your name.
5 My fairytale comes close to me.
6 And I know that I've got to keep.
7
8 Chorus
9 She let her head in my soul in a skirt.
10 Safe in the plastic prizes never changes.
11 You win my Grammy. you commin cause I came up to the people
   say.
12 With a boy in the corner so close.
13
14 Verse 2
15 You son of a hustla,. Of a cemetery in the car.
16 And then maybe it's just the way to turn.
17 I'll pray for me.
18 And if there's no way to you.
19
20 Chorus
21 She let her head in my soul in a skirt.
22 Safe in the plastic prizes never changes.
23 You win my Grammy. you commin cause I came up to the people
   say.
24 With a boy in the corner so close.
25
26 Chorus
27 She let her head in my soul in a skirt.
28 Safe in the plastic prizes never changes.
29 You win my Grammy. you commin cause I came up to the people
   say.
30 With a boy in the corner so close.
```

Como se puede observar, el texto carece de sentido alguno y en algunas ocasiones se observa que la cadena completa es parte de una canción, por lo que resulta peligroso si el usuario desea usar esta cadena por cuestiones de derecho de autor.

A continuación se muestra el código utilizando nuestra base de datos para generar texto usando cadenas de Markov:

```

1  import markovify
2  import random
3  import pandas as pd
4  import os
5
6  def versos(cantidad):
7      for sentence in range(cantidad):
8          generatedlyrics = markovifyModel.make_short_sentence(random.choice(
9              lenghtlyric))
10             print(generatedlyrics)
11
12 def generarcoros(cantidad):
13     for sentence in range(cantidad):
14         generatedlyrics = markovifyModel.make_short_sentence(random.choice(
15             lenghtcoros))
16         coro.append(generatedlyrics)
17
18 def printcoro():
19     for sentence in coro:
20         print(sentence)
21
22 lenghtversos = [4, 5, 6]
23 lenghtlyric = [80, 100, 120]
24 lenghtcoros = [60, 80, 100]
25 coro = []
26 m_columns = ['Lyric']
27 for _ in range(4): os.chdir('.')
28 path = os.path.abspath(os.getcwd()+"/Datasets" + "/Pop.csv")
29 df = pd.read_csv(path, encoding='latin-1', usecols=m_columns)
30 markovifyModel = markovify.Text(df['Lyric'])
31
32 markovifyModel = markovifyModel.compile()
33 generarcoros(random.choice(lenghtversos))
34 for beginning in range(1,2):
35     print("\nVerse " + str(beginning))
36     versos(random.choice(lenghtversos))
37 print("\nChorus")
38 printcoro()
39 for medium in range(3,4):
40     print("\nVerse " + str(medium))
41     versos(random.choice(lenghtversos))
42
43 print("\nChorus")
44 printcoro()
45
46 print("\nChorus")
47 printcoro()

```

En conclusión, se optó por no utilizar cadenas de Markov debido a que en ocasiones las oraciones que genera, en realidad es texto entero reutilizado de las oraciones que se encuentran en el dataset, de igual forma llegaron a salir resultados utilizando la misma palabra en repetidas ocasiones, se tiene en cuenta que los usuarios a los que va dirigido este proyecto, se encontrarán en posición de buscar ideas nuevas para su proyecto, ideas que contengan un sentido y palabras acordes a lo que ellos buscan, es por ellos que seguimos probando con otros algoritmos.

3.5.2. Pruebas con Recurrent Neural Networks

Como segunda prueba, se recurrió a utilizar este tipo de redes neuronales [85], y utilizando como optimizador adam[79] el cuál nos servirá para generar el modelo de la mejor forma de acuerdo con el artículo [80]se han tenido resultados satisfactorios utilizando este tipo de redes neuronales. En la sección de anexos 4.6 se mostrará el notebook hecho en jupyter para mostrar cada paso de la prueba junto con los resultados obtenidos.

3.6. Estudio de Factibilidad

El estudio de factibilidad es un instrumento que sirve para orientar la toma de decisiones, así como para determinar la posibilidad de desarrollar un negocio o un proyecto; corresponde a la última fase de la etapa pre-operativa del ciclo del proyecto. Se formula con base en información que tiene la menor incertidumbre posible para medir las posibilidades de éxito o fracaso de un proyecto, apoyándose en el resultado se tomará la decisión de proceder o no con su implementación.

Este estudio establecerá la viabilidad, si existe, del trabajo planteado previamente.

- **Factibilidad Técnica:** Este aspecto evalúa que la infraestructura, es decir, los equipos, el software, el conocimiento, la experiencia, etc. que se poseen son los necesarios para efectuar las actividades requeridas para la realización del trabajo terminal.
- **Factibilidad Operativa:** Analiza si el personal posee las competencias necesarias para el desarrollo del proyecto.
- **Factibilidad Económica:** Consiste en el análisis de los recursos financieros necesarios para llevar a cabo la elaboración de este proyecto.

3.6.1. Factibilidad Técnica

Dentro de este apartado se explican detalladamente las tecnologías que se utilizarán, así como las características de nuestros equipos de cómputo actualmente. La elección de estas herramientas estuvo basada tanto en las tecnologías que más se utilizan en la actualidad como las que cuentan con el mayor soporte para su trabajo en la nube, esto se debe a que los equipos con los que contamos actualmente no soportarían todo el trabajo.

Cuadro 3.4: Equipo de cómputo ideal

Equipo de cómputo ideal.	
Procesador	Intel i9 10900KF
Tarjeta de video	RTX 3080 10Gb
Memoria RAM	32Gb DDR4
Disco duro	2Tb HDD y 512Gb SSD

En la tabla anterior se muestra el equipo que requeriríamos para poder trabajar sin mayor dificultad al momento de realizar los entrenamientos de

los modelos de redes neuronales que necesitamos para la realización de este trabajo, debido a la situación actual de la pandemia, en el mercado actual los componentes para el equipo son escasos y su precio en el mercado aumento. Por esa razón se utilizarán servicios de la nube para la realización de estos entrenamientos y nuestros equipos para el desarrollo del resto del proyecto.

Cuadro 3.5: Herramientas de Software a utilizar

Herramientas de Software a utilizar	
Sistema Operativo	Linux, Mac, Windows
Navegador Web	Google Chrome
Lenguaje de Programación	Python
Servidor	Apache y Gunicorn
Servicio Nube	Amazon Web Services

Además de las herramientas de software a utilizar, es necesario mencionar el equipo de hardware que se utiliza, tanto para desarrollar, como para probar e implementar cada uno de los prototipos a lo largo de este trabajo terminal.

Cuadro 3.6: Equipo de cómputo 1

Equipo de cómputo utilizado. [1]	
Procesador	Ryzen 5 3600
Tarjeta de video	Amd Radeon Rx580
Memoria RAM	32 Gb
Disco duro	1Tb HDD y 512Gb SSD

Cuadro 3.7: Equipo de cómputo 2

Equipo de cómputo utilizado. [2]	
Marca	Apple
Modelo	iMac Late 2012
Procesador	Intel Core i5
Tarjeta de video	NVIDIA GeForce GT 640M 512 Mb
Memoria RAM	8 Gb
Disco duro	1Tb y 256 Gb SSD

Cuadro 3.8: Equipo de cómputo 3

Equipo de cómputo utilizado. [3]	
Procesador	Amd FX-8350
Tarjeta de video	Nvidia Geforce 1050ti
Memoria RAM	16 Gb
Disco duro	1Tb HDD

Junto con las herramientas de hardware y software a utilizar es necesario mencionar los servicios básicos que son relevantes para el desarrollo de este trabajo terminal como lo son:

- Luz Eléctrica
- Agua Potable
- Internet

Estos servicios forman parte de la factibilidad técnica ya que sin ellos no se podría realizar este proyecto y por eso mismo generan un costo, dicho costo se menciona en la Factibilidad Económica.

3.6.2. Factibilidad Operativa

A continuación se presenta una tabla con los recursos operativos del trabajo terminal que se calcularon con base en los recursos humanos con los que se cuenta actualmente y un análisis de las horas en las que el personal estará en operación:

Cuadro 3.9: Relación de horas de trabajo estimadas para la realización de este trabajo terminal

Horas a trabajar en el desarrollo del trabajo terminal					
Mes	No. de Días	Sábado y Domingo	Días hábiles	Horas de trabajo por día	Horas Totales
Marzo	31	8	22	2	44
Abril	30	8	15	2	30
Mayo	31	10	19	2	38
Junio	30	10	17	2	34
Agosto	31	10	18	2	24
Septiembre	30	8	20	2	40
Octubre	31	10	20	2	40
Noviembre	31	8	18	2	36

Con esto podemos concluir que contamos con 286 horas, suficiente tiempo para el desarrollo de este trabajo terminal, ya que las horas totales de trabajo están contempladas para cada uno de los integrantes del equipo

3.6.3. Factibilidad Económica

Luego de haber realizado el estudio de factibilidad técnica así como el operacional es necesario tomar en cuenta un estudio de factibilidad económica el cual desglosará todo el gasto económico realizado para la elaboración de este trabajo terminal:

- **Capital Humano:** Se tienen contemplados aproximadamente 36 días laborales, es decir, 288 horas para la elaboración de este trabajo terminal en el cual participaremos los tres integrantes
- **Capital Técnico:** Se cuenta con las viviendas y el equipo de cómputo principal de cada uno de los integrantes.

Respecto a los costos monetarios de todo el proyecto se toma a consideración lo siguiente:

- **Servicios**
Se considera un gasto mensual aproximado de \$1,400.00 que al ser multiplicado por todo el tiempo de elaboración contemplado nos da un total de \$11,200.00, por integrante.
- **Software**
Durante algunos periodos se va a hacer uso principalmente de herramientas gratuitas y de software libre, en cuanto al servicio en la nube se pretende hacer uso de AWS y trabajar inicialmente con los planes gratuitos que ofrece, en caso de que se lleguen a consumir los recursos de este plan, entonces se procederá a cambiarnos a otro plan superior donde el costo actual se cobra en \$ 0.15 centavos de dólar por hora de uso.
- **Hardware**
Se utilizarán los equipos de cómputo personal de cada integrante, lo que da un costo aproximado de \$24,012.00 aplicando los parámetros de vida útil de un equipo de cómputo y su depreciación anual del hardware.
- **Recursos Humanos**
Se estima un gasto aproximado de \$12,000.00 por cada integrante del equipo para la elaboración del proyecto con lo que se generará un gasto total de \$36,000.00

Tomando en cuenta el salario promedio de un desarrollador de software el cual es de \$15,000.00 mensuales (este dato fue obtenido de [mx.indeed.com](https://www.indeed.com)), se consideró este salario para el desarrollo del proyecto, el cual tendría una

duración de desarrollo de 8 meses aproximadamente, dando como resultado un salario total para los integrantes del equipo de \$360,000.00; el costo final del desarrollo de este trabajo terminal sería de:

\$453,612.00

Conclusión

Tras realizar el análisis el estudio de factibilidad de este proyecto es pertinente decir que los integrantes no cuentan con el apoyo financiero y que el hardware mencionado ya es propiedad de los integrantes, por lo que el trabajo terminal se califica como “*Viable*” iniciando de esta manera su implementación acorde con las fechas mencionadas.

3.6.4. Aspectos Económicos

Las herramientas que usaremos en el trabajo terminal y las cuales validarán la viabilidad del proyecto se presentan a continuación:

Herramientas OpenSource a utilizar en el presente trabajo terminal

- Datamuse API [61]
- MongoDB - SSPL* [62]
- BERT - Apache 2.0 [63]
- Apache - Apache 2.0 [64]
- React - MIT [65]
- Python - PSFL [66]
- Amazon - Elastic 2.0 y SSPL [67]

*SSPL: Aunque es clasificado como OpenSource por parte de MongoDB, al estar basado en la licencia de software libre de GPL3, la Iniciativa de Open Source (OSI) no la reconoce como licencia OpenSource al describirla como una licencia OpenSource “no genuina”.

Como se puede apreciar en el software presentado, las licencias son del tipo OpenSource con lo cual validamos la viabilidad económica del proyecto el cual no representará gasto monetario más allá del necesitado para el entrenamiento de la red neuronal, para el cual haremos uso de Amazon SageMaker

que tiene un costo de:

Cuota gratuita primeros 2 meses:

- Instancia de bloc de notas: 250 horas.
- Entrenamiento: 50 horas.

Cuotas:

- Instancia de bloc de notas (4 CPU's virtuales y 16Gb de memoria): 0.20 centavos de dólar/hora.
- Entrenamiento (4 CPU's virtuales y 16Gb de memoria): 0.23 centavos de dólar/hora.
- Procesamiento (4 CPU's virtuales y 16Gb de memoria): 0.20 centavos de dólar/hora.

3.6.5. Aspectos Legales

Copyright

Los derechos de autor son una forma de protección para obras originales de autoría fijadas en un medio de expresión tangible. Los derechos de autor cubren tanto las obras publicadas como las que no o son inéditas.[53]

Los derechos de autor protegen un gran rango de obras como lo son: obras literarias, obras musicales, obras pictóricas o escultóricas, coreografías, escenas dramáticas, producciones cinematográficas y demás audiovisuales, programas de cómputo, fotografías, entre muchas otras.

Originalidad

Los derechos de autor protegen la forma en que se expresan las ideas. Esta manera única de expresar las palabras, notas musicales, colores, formas, etc. son elegidas y organizadas u ordenadas. Es la expresión lo que hace que una obra sea original. Esto significa que puede haber muchos trabajos diferentes sobre la misma idea y todos de ellos estarán protegidos por derechos de autor, siempre y cuando expresen esta idea de una manera original.[54]

Según la Ley Federal del Derecho de Autor, la forma en cómo se expresa un autor al momento de crear su obra es lo que esta protegido por la ley ante acciones fraudulentas.[55]

Con base en la Ley Federal del Derecho de Autor Capitulo IV articulo 107 “Las bases de datos o de otros materiales legibles por medio de máquinas o en otra forma, que por razones de selección y disposición de su contenido constituyan creaciones intelectuales, quedarán protegidas como compilaciones.” [55]

Por ende las canciones generadas por nuestro sistema no se pretenden ni pueden registrar, ya que estos resultados generados serian nuestros.

3.7. Análisis de riesgo

Dentro de este apartado determinaremos la probabilidad de que surja alguna problemática o riesgo el cual pueda impactar el desarrollo del proyecto, ya sea en términos del cronograma, la calidad o los costos.

Algunos riesgos que enfrentaremos durante el desarrollo del proyecto son los siguientes:

- **Riesgo de costo**

Si sobrepasamos el costo de desarrollo previsto, quizá nos enfrentemos a problemas relacionados con el alcance y los requerimientos funcionales y no funcionales del proyecto.

Cuadro 3.10: Riesgo de costo

Riesgo: Costos Elevados	
Impacto: Medio alto (7).	Nivel: Alto (49)
Probabilidad: Medio alto (7)	

Costos Elevados



Figura 3.1: Matriz de Riesgo de Costo

■ Riesgo de calendario

Si se realizó una mala estimación del tiempo necesario para el desarrollo, si se asignaron mal los recursos, si hubo alguna afectación dentro del recurso humano, lo más probable es que el proyecto no se termine de desarrollar en el tiempo establecido.

Cuadro 3.11: Riesgo de calendario

Riesgo: Falta de Tiempo	
Impacto: Medio bajo (4).	Nivel: Medio Medio (16)
Probabilidad: Medio bajo (4)	


Falta de tiempo



Figura 3.2: Matriz de Riesgo de calendario

Si no logramos entender la complejidad de la herramientas que utilizaremos para el desarrollo del proyecto o nos toma demasiado tiempo que son nuevas para nosotros, como lo son la herramientas de AWS para la creación de los modelos de redes neuronales y su entrenamiento dentro de la misma plataforma, se podrían presentar problemas como: su integración a la página web, creación fallida de los modelos de redes neuronales, posible no adaptación con el hardware con el que contamos, entre otros.

Riesgo: Fallas de Equipos	
Impacto: Bajo (1).	Nivel: Bajo (7)
Probabilidad: Medio alto (7)	



Si no se plantean posibles soluciones a posibles problemas que se pueden presentar durante el proyecto, si no se presenta liderazgo por parte de alguno de los miembros, si existe una mala comunicación, falta de motivación y si no hay una monitorización, se puede ver mermado el avance del proyecto.

Cuadro 3.13: Riesgo operacional

Riesgo: Desorganización en el equipo	
Impacto: Medio bajo (4).	Nivel: Medio (16)
Probabilidad: Medio bajo (4)	




Figura 3.4: Matriz de Riesgo operacional

■ Riesgos externos

Factores externos que pueden afectar el desarrollo del proyecto pueden ser algún cambio en las leyes, cambio en alguna norma, desastre natural.

Cuadro 3.14: Riesgos externos

Riesgo: Factores Externos	
Impacto: Alto (10).	Nivel: Bajo (10)
Probabilidad: Bajo (1)	

Factores externos




Figura 3.5: Matriz de Riesgos externos




Figura 3.6: Matriz General de Riesgos

Se utilizó la herramienta llamada Matriz de Evaluación de Riesgos de ITM Platform para generar este análisis de riesgo. [71]

Capítulo 4

Diseño

4.1. Arquitectura del sistema

4.1.1. Descripción de la arquitectura del sistema

Para poder crear esta herramienta de apoyo para estudiantes o aficionados en el área musical con la creación de letras musicales, se propone crear un sistema basado en inteligencia artificial usando técnicas de procesamiento de lenguaje natural que pueda auxiliarlos y puedan lograr su meta propuesta.

El sistema se compone de tres bloques los cuales se comunicarán vía red:

1. **Base de datos:** En este módulo se almacenan los datos de canciones, se trabajará especialmente con una tabla que contenga como principales campos:
 - Artista
 - Género
 - Nombre de la Canción
 - Letra
 - Idioma

Dicha base de datos se almacenará en un sistema especializado que se conecte a la nube para poder trabajar y almacenar estos datos sin mayor problema.

2. **Modelado de la red neuronal:** Este bloque va ser el encargado de generar las letras musicales para cada usuario que ingrese . Para la generación de dichas letras musicales, se utiliza un servicio en la nube para procesar la solicitud del usuario.

3. **Página Web:** Este primer bloque es el que se encuentra directamente enlazado con el usuario de nuestro sistema y al mismo tiempo con el servicio en la nube que aloja a las redes neuronales, el usuario utilizando su navegador podrá realizar peticiones al servicio en la web.

4.1.2. Funcionamiento General del Sistema

El siguiente diagrama muestra como se espera que quede el funcionamiento general del proyecto.

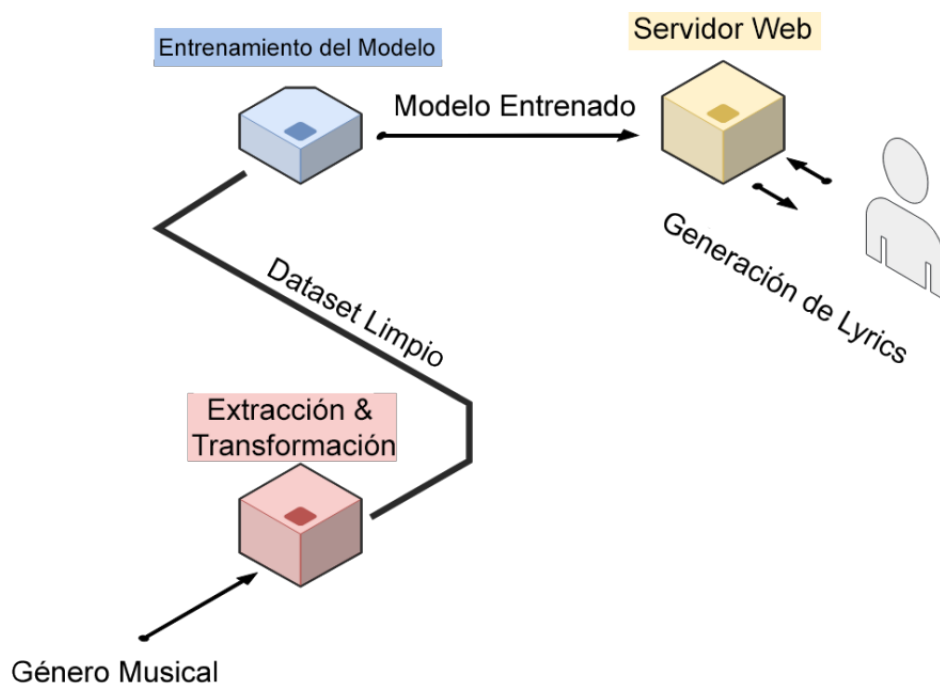


Figura 4.1: Diagrama general del sistema

Como se observa en la figura anterior, se tendrán tres procesos principales para lograr el objetivo final.

En primer instancia se tendrá que obtener la base de datos y por medio de extracción y transformación, se obtendrá el dataset deseado para poder generar el modelo.

Después de un proceso de limpieza de este dataset, se hará un entrenamiento del modelo en la nube para poder generar funciones utilizando este modelo para poder generar textos. una vez teniendo esta aplicación funcional, se

configurará el servidor web para que se pueda comunicar con el usuario final y con la aplicación que utiliza el modelo vía web, logrando así los objetivos.

4.1.3. Diagrama caso de uso

A continuación mostramos el caso de uso de nuestra aplicación web y su interacción con el usuario:




Figura 4.2: Diagrama de caso de uso

4.1.4. Historias de Usuario

Cuadro 4.1: Historia de Usuario 1

Historia de Usuario 1	
Nombre: Generar una letra de canción.	Usuario: Visitante
Descripción: Como un visitante de la página web quiero generar una letra de una canción a partir de una palabra que proporcione.	Validación: Con la palabra proporcionada por el usuario y con ayuda del modelo entrenado se generará una letra musical relacionada a esta.

Cuadro 4.2: Historia de Usuario 2

Historia de Usuario 2	
Nombre: Descargar una letra canción.	Usuario: Visitante
Descripción: Como un visitante de la página web quiero poder descargar la letra de la canción que se generó a partir de la palabra que proporcioné.	Validación: El usuario podrá descargar un archivo de texto que contendrá la letra de la canción generada.

Cuadro 4.3: Historia de Usuario 3

Historia de Usuario 3	
Nombre: Definir que tanto deseo que rime una canción	Usuario: Visitante
Descripción: Me gustaría tener una opción en la cual pueda definir que tanto quiero que rime una canción, desde que no rime nada hasta que rime toda.	Validación: Se genera una letra de canción con lo parámetros de rima que establece el usuario.

Cuadro 4.4: Historia de Usuario 4

Historia de Usuario 4	
Nombre: Generar otra letra de canción con los mismos parámetros	Usuario: Visitante
Descripción: Como usuario, me gustaría generar otra letra de canción con los mismo parámetros y palabra que ya había introducido.	Validación: Brindar una opción al usuario que una vez generada y desplegada la letra de la canción pueda generar otra usando los mismo parámetros que previamente había introducido.

Cuadro 4.5: Historia de Usuario 5

Historia de Usuario 5	
Nombre: Validación de la palabra introducida.	Usuario: Sistema
Descripción: La página web validará la palabra proporcionada por el usuario para con ella hacer la petición al servidor y generar una letra de canción relacionada a esta.	Validación: Con ayuda del modelo y la palabra introducida y procesada por la página web se genera y despliega la letra generada.

Cuadro 4.6: Historia de Usuario 6

Historia de Usuario 6	
Nombre: Limpiar base de datos.	Usuario: Desarrollador
Descripción: Como un desarrollador quiero una base de datos sin caracteres especiales o palabras repetidas.	Validación: Con ayuda de un script para quitar palabras innecesarias y caracteres inválidos

Cuadro 4.7: Historia de Usuario 7

Historia de Usuario 7	
Nombre: Preprocesar la base de datos.	Usuario: Desarrollador
Descripción: Como un desarrollador quiero generar el modelo solo con los datos necesarios para optimizar los tiempos de entrenamiento.	Validación: Con un script para tokenizar y hacer pre-padding en la base de datos

Cuadro 4.8: Historia de Usuario 8

Historia de Usuario 8	
Nombre: Subir Base de Datos a la nube.	Usuario: Desarrollador
Descripción: Como un desarrollador quiero generar el modelo con los datos necesarios en la nube para optimizar espacio local.	Validación: Utilizando herramientas NOSQL para subir la base de datos y esta no ocupe espacio local

Cuadro 4.9: Historia de Usuario 9

Historia de Usuario 9	
Nombre: Generar Modelo en la nube.	Usuario: Desarrollador
Descripción: Como un desarrollador quiero generar nuevas letras de canciones a partir de un dataset proporcionado anteriormente.	Validación: Con un script en una plataforma en línea entrenar el modelo para generar nuevas canciones

Cuadro 4.10: Historia de Usuario 10

Historia de Usuario 10	
Nombre: Generar Modelo en la nube.	Usuario: Desarrollador
Descripción: Como un desarrollador quiero generar nuevas letras de canciones a partir de un dataset limpio proporcionado anteriormente.	Validación: Con un script en una plataforma en línea entrenar el modelo para generar nuevas canciones

Cuadro 4.11: Historia de Usuario 11

Historia de Usuario 11	
Nombre: Probar respuestas del modelo en la nube.	Usuario: Desarrollador
Descripción: Como un desarrollador quiero generar nuevas letras de canciones a partir del modelo generado en la nube	Validación: Con una función que genere algunos ejemplos usando el modelo generado en la nube

Cuadro 4.12: Historia de Usuario 12

Historia de Usuario 12	
Nombre: Desarrollar la vista del usuario (Página Web).	Usuario: Desarrollador
Descripción: Como un desarrollador Quiero que el usuario tenga una vista intuitiva y fácil de utilizar con la que pueda generar sus lyrics apropiadamente.	Validación: Creando la página web con vistas sencillas y ordenadas para que el usuario no se pierda en la navegación en ella.

Cuadro 4.13: Historia de Usuario 13

Historia de Usuario 13	
Nombre: Conectar la vista del usuario con el modelo.	Usuario: Desarrollador
Descripción: Como un desarrollador Quiero que la vista del usuario y el modelo funcionen en conjunto para que se pueda generar la lyric de la canción y se vea apropiadamente.	Validación: Conectando la página web con el modelo generado y las funciones para generar una lyric nueva

4.1.5. Requerimientos funcionales y no funcionales

A continuación, se presentan los requerimientos funcionales mas importantes de nuestro proyecto:

- RF1: Permitirá a cualquier usuario que acceda a la página, generar uno o más versos musicales.
- RF2: Permitirá al usuario descargar la letra generada como archivo de texto.
- RF3: Permitirá al usuario generar cuantas veces quiera una letra musical.
- RF4: Solo se generarán las letras musicales si se cumplen todos los

requisitos obligatorios proporcionados por el usuario, los cuales serán: una palabra y el porcentaje de rima de la canción.

Ahora, se presentan algunos de los requerimientos no funcionales más importantes de nuestro proyecto

- RNF1: El servicio web debe ser capaz de procesar más de diez solicitudes simultáneas.
- RNF2: La página debe ser capaz de operar adecuadamente con hasta cincuenta usuarios simultáneamente.
- RNF3: El tiempo que le toma a un usuario promedio en el aprendizaje del sistema de la interfaz deberá de ser menor a cinco minutos.
- RNF4: La página proporcionará alertas de error que sean informativos y que ayuden a la experiencia de usuario.
- RNF5: La aplicación web debe tener un diseño responsivo, es decir, que garantice una adecuada visualización tanto en computadoras, tabletas y dispositivos móviles.

4.2. Base de Datos

4.2.1. Descripción

En este apartado se hará el diseño de la base de datos para poder generar un modelo acorde a los requerimientos funcionales del proyecto.

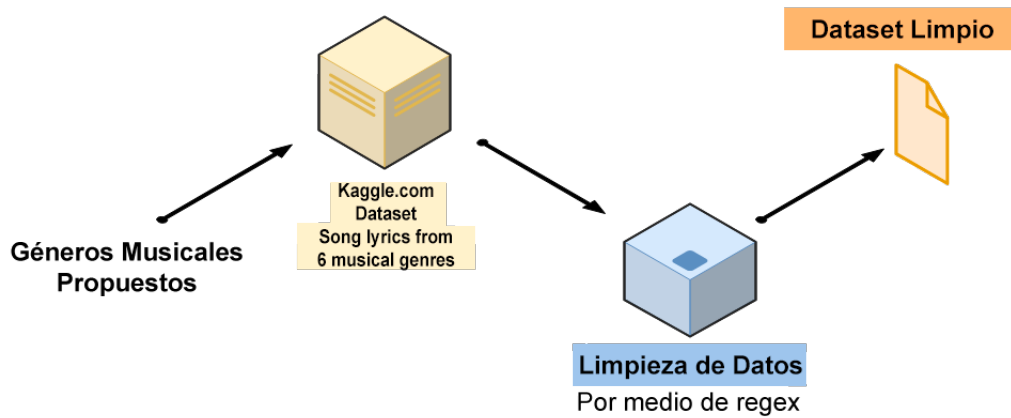


Figura 4.3: Diagrama de obtención de dataset

4.2.2. Obtención de la Base de Datos

Para iniciar la búsqueda de la base de datos primero se eligieron las características esenciales que se muestra a continuación para poder generar el modelo:

- Letra de la canción.
- Idioma.
- Artista.

Se hizo la búsqueda de datasets con estas características en páginas que contienen datasets con licencia del tipo open source, tales como Kaggle [73],

Google datasets [74], AWS Open Data [75] y en papers de investigación.

Encontramos diferentes datasets que contaban con algunas de las necesidades del sistema pero por una u otra razón no se podían utilizar, tal fue el caso del dataset de Music4All [76] que contaba con las necesidades del sistema pero el uso de los datos era muy restringido.

En Kaggle [73] se encontró un dataset llamado “Song lyric for 6 musical genres” [72] el cual contiene todos los datos necesarios para el sistema con un total de 160,790 letras de canciones con las tablas mostradas a continuación:




Figura 4.4: Diagrama Entidad Relación de la Base de Datos

Dicha base de datos se sacó originalmente de la página de Vagalume [77] e incluye 6 tipos de géneros musicales mencionados a continuación, los cuales son:

- Rock
- Pop
- Hip Hop
- Samba
- Sertanejo

- Funk Carioca

Se cuenta con dos tablas que cumplen con las características ideales para realizar el modelo acorde a los requerimientos funcionales.

Como se puede observar, se tienen las columnas “Genre” que utilizaremos para separar el dataset en géneros musicales y “Link” que servirá como enlace a la segunda tabla.

Se utilizarán las columnas de “Lyric” para poder entrenar el modelo, “Idiom” para seleccionar y utilizar las canciones en el idioma inglés y “ALink” que nos servirá para fusionar la tabla mencionada anteriormente con la actual y así poder usar esas columnas, quedando un resultado como en la siguiente figura:

Songs_with_Artists	
id	int
ALink	varchar[30]
SName	varchar[30]
SLink	varchar[60]
Lyric	varchar[500]
Idiom	varchar[15]
Artist	varchar[30]
Popularity	float
Link	varchar[30]
Genre	varchar[20]
Genres	varchar[100]

Figura 4.5: Diagrama Entidad Relación de la Base de Datos

4.2.3. Género Musical

El género musical que elegimos es Pop en inglés debido a que es un género musical flexible en su estructura y en su léxico, otros géneros contemplados fueron Hip Hop y Rock que también cuentan con un extenso catálogo de datos pero se encontraron modelos que ya utilizan esos géneros.

4.2.4. Resultados

Al necesitar extraer información precisa para el entrenamiento del modelo no es necesario que la base de datos sea muy compleja, razón por la cual las tablas mostradas en el diagrama entidad-relación se ve así, siendo lo de mayor relevancia el mostrar que un artista puede tener muchas canciones pero una canción le pertenece únicamente a un artista.

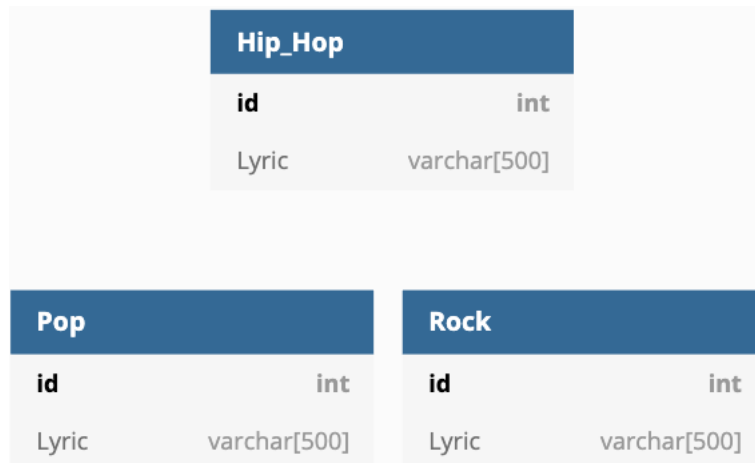


Figura 4.6: Diagrama Entidad Relación de las tablas Finales

4.3. Limpieza de la Base de Datos

4.3.1. Descripción

Una vez obtenida la base de datos, es necesario hacer una inspección de esta misma para verificar que los estos datos sean útiles para proceder a generar un modelo, este paso resulta de suma importancia, ya que de esto depende que la precisión de los resultados del modelo.

Para ello se identificarán datos que resulten incompletos, incorrectos, inexactos, no pertinentes para luego sustituirlos, modificarlos o en su caso, eliminar estos datos.

Una vez realizada esta limpieza, la base de datos será compatible con el entrenamiento y los resultados generados al final serán más entendibles.

Estas inconsistencias en el conjunto de datos pueden ser causados por errores de entradas del usuario, corrupción de los datos, errores en el área de scraping, o simplemente tienen caracteres que no nos interesa procesar.

Se utilizará la librería de “Pandas” y en caso de que se requiera, utilizar la librería de expresiones regulares para hacer esta limpieza, estas dos librerías de Python ayudarán a que los datos puedan ser utilizados para realizar el debido preprocesamiento como siguiente paso sin tener que cambiar cada campo manualmente, lo que mejora la eficiencia para poder lograr el objetivo propuesto.

Para limpiar los datos seguiremos el estándar de limpieza de datos:[56]

1. Remover caracteres innecesarios
2. Eliminar Duplicados
3. Evitar errores ortográficos o errores de similitud
4. Convertir los tipos de dato
5. Tratar los valores nulos o faltantes

4.3.2. Remove caracteres innecesarios

Es necesario remover este tipo de elementos del conjunto de datos para que al momento de entrenar el modelo, no arroje resultados con valores ilegibles o incluso, que no se pueda tratar la base de datos correctamente.

Para este paso, es necesario tener conocimiento de expresiones regulares básicas para poder delimitar los espacios dobles, letras o caracteres especiales ilegibles, saltos de línea, tabuladores, entre otros que puedan causar errores en los siguientes pasos.

4.3.3. Eliminar Duplicados

Pueden existir datos duplicados dentro de la base de datos que para el entrenamiento sería inútil además que solicitaría recursos innecesarios al sistema el meter más datos de los necesarios, para ello, con la función `drop.duplicates()` de pandas, se podrá lograr el cometido sin problema alguno.

4.3.4. Evitar errores ortográficos o errores de similitud

Existen librerías en el idioma inglés para corregir la ortografía, en este proyecto se quiere generar la letra apegada a la jerga utilizada en el idioma para poder generar las nuevas letras de canciones, por lo que no será necesario hacer a profundidad este paso.

4.3.5. Convertir los tipos de dato

Se va a corroborar que todas las celdas contengan únicamente el tipo varchar con un límite de 500 caracteres, número elegido al tener una media de todos los elementos de 350 caracteres aproximadamente. El número de filas que contienen más de 500 caracteres es muy bajo por lo que al cortar las canciones que tienen más puede ayudar a ahorrar la memoria utilizada a la hora del entrenamiento.

4.3.6. Tratar los valores nulos o faltantes

Tener datos nulos en el entrenamiento puede llegar a ser fatal debido a que además de utilizar memoria en el entrenamiento, a la hora de generar resultados, estos resultan en resultados nulos, además que tratar la misma base de datos a la hora del preprocesamiento puede arrojarnos errores a la hora de manipular la base de datos.

4.3.7. Resultados

Una vez realizada esta limpieza general del conjunto de datos, el resultado esperado es tener una base de datos útil y solo con los datos necesarios para poder tratarlos con el debido proceso para empezar el preprocesamiento de entrenamiento del modelo de la red neuronal, este proceso es necesario hacer solo una sola vez para cada género musical ingresado, en caso de que se lleguen a necesitar más datos, será necesario repetir el proceso para poder generar resultados de la manera más óptima posible. A continuación se muestran las primeras líneas de la base de datos limpias.

	Lyric
0	Hey, slow it down. What do you want from me. W...
1	Died last night in my dreams. Walking the stre...
2	I've paid my dues. Time after time. I've done ...
3	So I got my boots on,. Got the right amount of...
4	I wish that this night would never be over. Th...

Figura 4.7: Resultados de Limpieza de Base de Datos

4.4. Modelo para Neural Network

4.4.1. Descripción

En este apartado expondremos las herramientas pensadas para el desarrollo del modelo de red neuronal, así como la manera en que se piensa que se puedan integrar a nuestro proyecto y las conexiones que puede tener tanto con la base de datos como con el servidor en la nube o la interfaz web.

4.4.2. Herramientas usadas para generar el modelo

Se decido trabajar con BERT en lugar de GPT-2 debido a que usando BERT podemos entrenarlo y ajustarlo a resultados que consideramos satisfactorios, cosa que no es posible usando GPT-2, además BERT cuenta con la característica de ser Bidireccional, el cual nos permite analizar el texto anterior para poder generar el texto futuro.

BERT (Bidirectional Encoder Representations from Transformers) se usará para clasificar oraciones, este se puede entender de forma más sencilla de la siguiente manera:

- Bidirectional: Para entender el texto es necesario dar un vistazo hacia atrás (a las palabras previas) y hacia adelante (a las palabras que siguen).
- Transformers: El Transformer lee secuencias enteras de tokens de una vez. En un sentido, el modelo es no-direccional, mientras que las redes del tipo LSTM (Long-Short Term Memory) leen de forma secuencial (izquierda-derecha o derecha-izquierda). El mecanismo de atención permite aprender relaciones contextuales entre palabras.

4.4.3. Modelo

Para el diseño del modelo se tiene contemplado el siguiente modelo del cual se puede decir que una vez se tiene la salida del transformer se pasa por una capa de clasificación, posterior a ello se usa la función “Softmax” de Python para calcular la probabilidad de aparición de cada palabra que se tiene en el vocabulario y cuyo resultado final determinará la palabra usada para la máscara (marcada de color rojo).

En última instancia, y de acuerdo a la probabilidad de rima dada por el

usuario en la interfaz web, la última palabra puede o no contener una rima que haga juego con alguna de las palabras de la oración previa del verso.

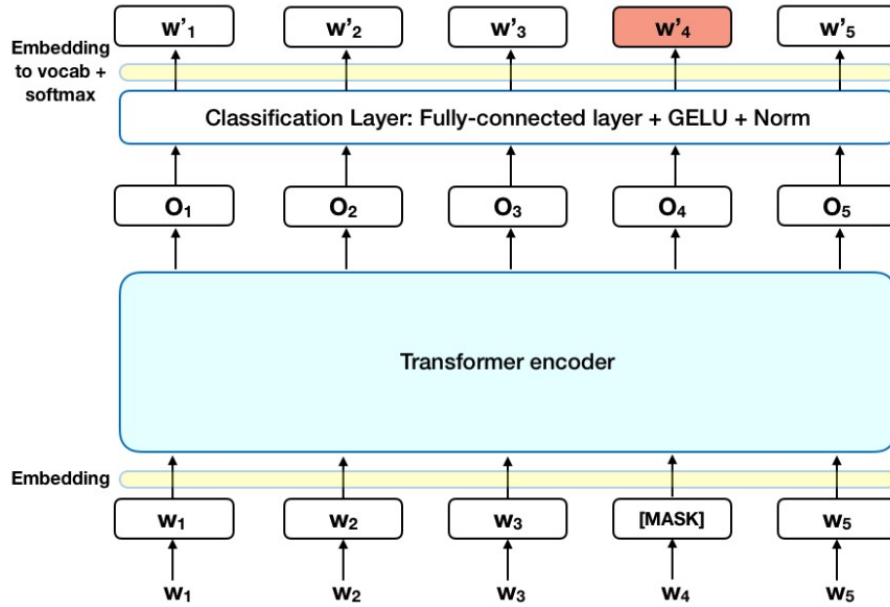


Figura 4.8: Diagrama de diseño del modelo

4.4.4. Resultados

Habiendo hecho el análisis del modelo anterior y tomándolo como referencia para nuestro proyecto podemos adaptarla de forma tal que las entradas sean en su mayoría [MASK] las cuales serán las palabras predichas siendo la razón por la cual todas las palabras derivadas de esto están en rojo ya que representan una entradas del tipo MASK, y la última palabra [RHYME] estará dada por el porcentaje de coincidencia seleccionado por el usuario y que tiene como objetivo, valga la redundancia, de rimar con la última palabra de la penúltima oración previa:




Figura 4.9: Diagrama de diseño del modelo

Siendo el resultado esperado uno muy similar a la estructura que se muestra a continuación y en la que se puede ver lo siguiente:

En todos los casos la palabra que rime tendrá un valor entre 0 y 1 (valor flotante) el cual determinará qué tan alta sería la posibilidad de que la palabra rime, siendo el valor 0 que no rime y el valor 1 representaría una rima segura.

Verso

- Estará compuesto de 4 a 6 oraciones y el valor será decidido por un número al azar.
- Las palabras que serán predichas en todo el verso serán de 4 a 5 y el valor será decidido por un número al azar.

Pre-coro y puente

- Estará compuesto de 2 a 3 oraciones y el valor será decidido por un número al azar.
- Las palabras que serán predichas en todo el verso serán de 6 a 10 y el valor será decidido por un número al azar.

Coro

- Estará compuesto de 3 a 4 oraciones y el valor será decidido por un número al azar.
- Las palabras que serán predichas en todo el verso serán de 3 a 8 y el valor será decidido por un número al azar.




Figura 4.10: Diseño de la estructura del modelo

4.5. Generación del Modelo en la Nube

4.5.1. Descripción

En este apartado se hablará de las herramientas que utilizaremos, la interacción entre el desarrollador y el sistema para suministrar la base de datos a Amazon Sagemaker, el desarrollo que seguirá AWS para ir desde el entrenamiento del modelo hasta el despliegue del mismo para poder ser utilizado. El diagrama a continuación muestra el funcionamiento general para este capítulo:




Figura 4.11: Diagrama de instancias de AWS

Como se observa, se ingresará la base de datos generada y se utilizará una instancia EC2, que a su vez usará en caso de necesitar más recursos un bucket de S3 para crear checkpoints resultando con el modelo entrenado a través de un número dado de epochs.

4.5.2. Amazon Sagemaker

Amazon SageMaker es un servicio que ayuda a científicos y desarrolladores a construir, entrenar e implementar de manera rápida y sencilla modelos de machine learning de forma rápida. SageMaker suprime las tareas difíciles y tediosas de cada paso del proceso de machine learning para que sea más fácil crear modelos de alta calidad.

Dentro de las virtudes de SageMaker, y razón por la cual lo preferimos sobre la competencia, es que cuenta con 2 herramientas esenciales las cuales nos servirán al momento de entrenar el modelo:

- SageMaker Experiments: Ayuda a organizar y rastrear iteraciones en los modelos de aprendizaje automático al capturar los parámetros de entrada, configuraciones y resultados y guardarlos como “experimentos”, permitiendo que de forma posterior se pueda llevar una línea de tiempo de lo que ha sucedido y comparar los resultados de los experimentos de una manera visual.
- SageMaker Debugger: Registra métricas del entrenamiento en tiempo real, genera advertencias y consejos de solución cuando se detectan problemas de entrenamiento comunes, así como monitorea los recursos del sistema para brindar recomendaciones respecto a cómo reasignar recursos y así reducir los costos.
- Managed Spot Training: Es una herramienta que permite entrenar los modelos de aprendizaje automático con instancias de Amazon EC2 que pueden demorar más al entrenar a cambio de abaratar los costos de entrenamiento hasta en un 90 %.

4.5.3. Suministrado de Datos

Al ingresar a SageMaker lo primero que nos es requerido hacer es una instancia bloc de notas (Jupyter Notebook) dentro del cual escribiremos el código en Python que ocuparemos para ejecutar todo el procedimiento visto en la iteración tres.

Instancia de bloc de notas

Dentro de Amazon Sagemaker creamos un bloc de notas (Jupyter Notebook) dentro del cual podremos operar con código Python y el cual tiene como ventaja principal el correr código por bloques evitando de esta manera el tener que reescribirlo y pudiendo correr todo de manera secuencial nuevamente o insertar nuevos bloques entre los previamente creados según veamos más conveniente.




Figura 4.12: Instancia creada en AWS

Dentro de la instancia de Jupyter se va a realizar lo siguiente:

- Filtrar y preparar el contenido del dataset que le proporcionemos.
- Entrenar el modelo, el cual podremos supervisar desde una instancia proporcionada por Amazon SageMaker durante este paso llamado “Instancia de Entrenamiento de Aprendizaje de Máquina”.
- Generar el modelo.
- Desplegar el modelo, para este paso de la misma forma que ocurre con el entrenamiento del modelo, Sagemaker proporciona una instancia que nos permitirá alojarlo para su posterior uso llamada “Instancia de Alojamiento de Aprendizaje de Máquina”.

Posterior a todos los pasos mencionados anteriormente que se realizarán dentro de la instancia de Jupyter se puede crear ahí mismo un ‘API endpoint’ que responderá a una petición hecha por el usuario para acceder al modelo generado y así generar y devolver la letra de la canción.

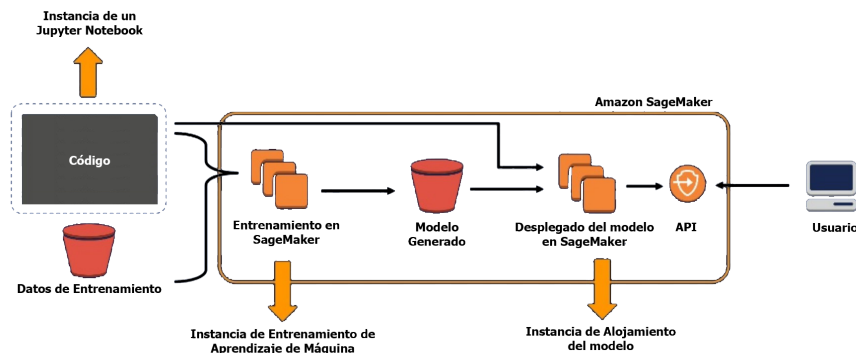


Figura 4.13: Diagrama del funcionamiento de SageMaker

Como se puede apreciar en el diagrama, dentro de Amazon SageMaker ocurrirán todos los procesos que requerimos se ejecuten para poder entrenar y generar el modelo al que el usuario final podrá contactar por medio de una API para solicitar una letra de la canción según sus requerimientos especificados.

4.5.4. Resultados

De manera similar a la tratada para la generación del modelo de neural network, consistirá de un proceso muy similar al seguido en ese apartado con el diferenciador principal siendo que será en la nube, e incluso de una manera muy simple podríamos resumir los pasos a seguir del siguiente diagrama (tomado de nuestra arquitectura del sistema) y el cual simplifica aún más el proceso seguido por Amazon SageMaker para la generación del Modelo.




Figura 4.14: Diagrama simple del proceso seguido para generar el modelo en la nube

4.6. Aplicación web




Figura 4.15: Diagrama de conexión entre modelo y usuario

La figura anterior, muestra el funcionamiento general entre la aplicación del modelo entrenado para generar lyrics en línea y el usuario final a través de un webserver de Apache. En este apartado se mostrará un primer boceto de las vistas de la aplicación web.

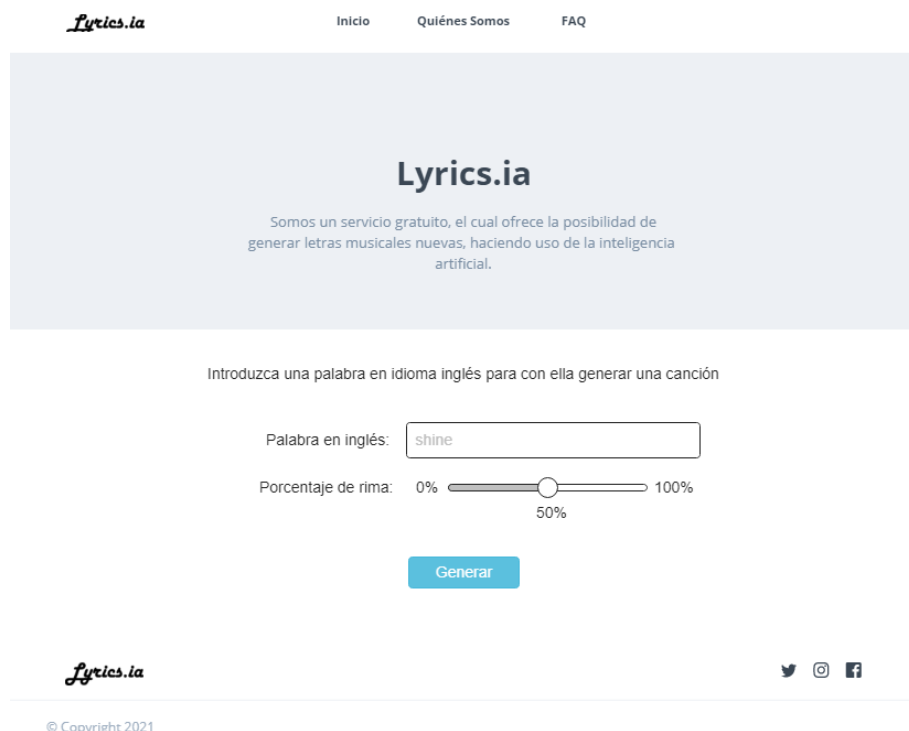


Figura 4.16: Aplicación web, pagina inicial.




Figura 4.17: Aplicación web, pagina una vez generada una letra musical.

Anexos

Cadenas de Markov

Una cadena de Markov es un proceso estocástico de tiempo discreto: un proceso que ocurre en una serie de pasos de tiempo, en cada uno de los cuales se hace una elección aleatoria. Una cadena de Markov consta de N estados.

Una cadena de Markov se caracteriza por una matriz de probabilidad de transición $N \times N$, P cada una de cuyas entradas está en el intervalo $[0, 1]$; las entradas en cada fila de P suman 1. La cadena de Markov puede estar en uno de los estados N en cualquier paso de tiempo dado; luego, la entrada P_{ij} nos dice la probabilidad de que el estado en el siguiente paso de tiempo sea j , condicionado a que el estado actual sea i . Cada entrada P_{ij} se conoce como probabilidad de transición y depende solo del estado actual i ; esto se conoce como propiedad de Markov. Así, la propiedad de Markov puede definirse de la siguiente manera: Ecuación 1 :

$$\forall i, j, P_{ij} \in [0, 1]$$

Y ecuación 2:

$$\forall i, \sum_{j=1}^N P_{ij} = 1.$$

Una matriz con entradas no negativas que satisface la Ecuación 2 se conoce como matriz estocástica. Una propiedad clave de una matriz estocástica es que tiene un vector propio izquierdo principal correspondiente a su valor propio más grande, que es 1.

En una cadena de Markov, la distribución de probabilidad de los siguientes estados para una cadena de Markov depende solo del estado actual y no de cómo llegó la cadena de Markov al estado actual. La siguiente figura muestra una cadena de Markov simple con tres estados. Desde el estado medio A, procedemos con probabilidades (iguales) de 0.5 a B o C. Desde B o C, procedemos con probabilidad 1 a A. La matriz de probabilidad de transición de esta cadena de Markov es entonces:

$$\begin{pmatrix} 0 & 0.5 & 0.5 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

La distribución de probabilidad de una cadena de Markov sobre sus estados




Figure 1: Una cadena de Markov simple con tres estados; los números en los enlaces indican las probabilidades de transición.

puede verse como un vector de probabilidad: un vector en cuyas entradas están en el intervalo $[0, 1]$, y las entradas suman 1. Un vector de probabilidad N -dimensional, cuenta con componentes correspondientes a uno de los estados N de una cadena de Markov, puede verse como una distribución de probabilidad sobre sus estados. Para nuestra cadena de Markov simple de la figura 1, el vector de probabilidad tendría 3 componentes que suman 1.

Podemos ver a un internauta aleatorio en el gráfico web como una cadena de Markov, con un estado para cada página web, y cada probabilidad de transición

representa la probabilidad de pasar de una página web a otra. La operación de movilizarse contribuye a estas probabilidades de transición. La matriz de adyacencia A del gráfico web se define de la siguiente manera: si hay un hipervínculo desde la página i a la página j , entonces $A_{ij} = 1$, de lo contrario $A_{ij} = 0$. Podemos derivar fácilmente la matriz de probabilidad de transición P para nuestra cadena de Markov a partir de la matriz $N \times N$ A :

1. Si una fila de A no tiene 1, reemplace cada elemento por $1/N$. Para todas las demás filas, proceda de la siguiente manera.
2. Divida cada 1 en A por el número de 1 en su fila. Por lo tanto, si hay una fila con tres unos, cada uno de ellos se reemplaza por $1/3$.
3. Multiplica la matriz resultante por $1 - \alpha$.
4. Agregue α/N a cada entrada de la matriz resultante, para obtener P .

Podemos representar la distribución de probabilidad de la posición del internauta en cualquier momento mediante un vector de probabilidad \vec{x} . En $t = 0$, el internauta puede comenzar en un estado cuya entrada correspondiente en \vec{x} es 1 mientras que todos los demás son cero. Por definición, la distribución del internauta en $t = 1$ viene dada por el vector de probabilidad $\vec{x}P$; en $t = 2$ por $(\vec{x}P)P = \vec{x}P^2$, y así sucesivamente. Por lo tanto, podemos calcular la distribución del internauta sobre los estados en cualquier momento, dada solo la distribución inicial y la matriz de probabilidad de transición P .

Si se permite que una cadena de Markov se ejecute durante muchos pasos de tiempo, cada estado se visita a una frecuencia (diferente) que depende de la estructura de la cadena de Markov. En nuestra analogía de ejecución, el internauta visita ciertas páginas web (por ejemplo, páginas de inicio de noticias populares) con más frecuencia que otras páginas. Ahora hacemos esta intuición precisa, estableciendo las condiciones bajo las cuales la frecuencia de visita converge a una cantidad fija en un estado estable.

Este documento fue publicado por: Cambridge University Press (Julio 04, 2009) Markov chains. [En línea]. Disponible: <https://nlp.stanford.edu/IR-book/html/htmledition/markov-chains-1.html#fig:figmarkov>

Pop Lyric Generator

Text Generation is a type of Language Modelling problem.

Language Modelling is the core problem for a number of Natural Language Processing tasks such as speech to text, conversational system, and text summarization, etc.

Text Generation is a task which can be be architected using deep learning models, particularly Recurrent Neural Networks.

In this project, we will experiment to generate new pop lyrics based on [this Dataset](https://www.kaggle.com/neisse/scrapped-lyrics-from-6-genres) (<https://www.kaggle.com/neisse/scrapped-lyrics-from-6-genres>).

Import Libraries

We have to import the libraries we're going to use, the most relevant are:

- **Pandas** in order to manipulate and analyze the data
- **Matplotlib** to visualize the data in graphics
- **Wordcloud** to help us when we are going to generate the next word of a sentence
- **Tensorflow & Keras** will help us in the process of machine learning and keras for deep learning.

In [1]:

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from wordcloud import WordCloud, STOPWORDS, ImageColorGenerator
import string, os
import tensorflow as tf

# keras module for building LSTM
from keras.preprocessing.sequence import pad_sequences
from tensorflow.keras.layers import Embedding, Dropout, LSTM, Dense, Bi
directional
from keras.preprocessing.text import Tokenizer
from keras.callbacks import EarlyStopping
from keras.models import Sequential
```

Loading the Dataset

Once the Data was precleaned, it's going to be imported to the cloud. As it's mentioned in the documentation, it's on .csv because is easier to manipulate the data using Pandas library.

In [2]:

```
# Import csv file
df = pd.read_csv('../input/pop-lyrics/Pop.csv')
```

In [3]:

```
# Print first 10 rows to confirm is the right dataset
df.head()
```

Out[3]:

	Unnamed: 0	Artist	Songs	Popularity	ALink	Genre	Genres	SName	SLink
0	0	Adam Lambert	110	1.4	/adam-lambert/	Pop	Pop; Pop/Rock; Rock; Rom�ntico; Dance; Electr...	Whataya Want From Me	/adam-lambert/want-from-me.htm
1	1	Adam Lambert	110	1.4	/adam-lambert/	Pop	Pop; Pop/Rock; Rock; Rom�ntico; Dance; Electr...	Ghost Town	/adam-lambert/town.ht
2	2	Adam Lambert	110	1.4	/adam-lambert/	Pop	Pop; Pop/Rock; Rock; Rom�ntico; Dance; Electr...	We Are The Champions (feat. Kris Allen & Queen)	/adam-lambert/the-champions-feat-kris-allen-queen.htm
3	3	Adam Lambert	110	1.4	/adam-lambert/	Pop	Pop; Pop/Rock; Rock; Rom�ntico; Dance; Electr...	If I Had You	/adam-lambert/if-i-had-you.htm
4	4	Adam Lambert	110	1.4	/adam-lambert/	Pop	Pop; Pop/Rock; Rock; Rom�ntico; Dance; Electr...	Never Close Our Eyes	/adam-lambert/never-close-our-eyes.htm

Data Cleaning

In this step the dataset is going to be cleaned using Pandas library to remove the columns that are not going to be used and keep only the unique column called "Lyrics".

DATA CLEANING CHECKLIST

Up-to-date data



Data should be up-to-date in order to obtain maximum value from the data analysis.



Missing values



Count missing values and analyze where in the data they are missing. Missing values can disrupt some analyses and skew the results.



Duplicates



Duplicate IDs indicate multiple records for one person, e.g. someone holds multiple functions at the same time.



Numerical outliers



Numerical outliers are fairly easy to detect and remove. Define minimum and maximum to spot outliers easily.



Check IDs



Check data labels of all the fields to see whether some categorical values are mislabeled.



Define valid output



Define valid data labels for categorical data. Define data ranges for numerical variables. Non-matching data is presumably wrong.



In [4]:

```
# Drop all the columns except Lyrics
df.drop(['Artist', 'Songs', 'Popularity', 'Genre', 'Genres', 'Idiom', 'ALink',
        'SName', 'SLink'], axis=1, inplace=True)
df.drop(df.columns[df.columns.str.contains('unnamed', case = False)], axis = 1, inplace = True)
```

In [5]:

```
# Print first 10 rows to confirm the drops were made correctly
df.head()
```

Out[5]:

	Lyric
0	Hey, slow it down. What do you want from me. W...
1	Died last night in my dreams. Walking the stre...
2	I've paid my dues. Time after time. I've done ...
3	So I got my boots on,. Got the right amount of...
4	I wish that this night would never be over. Th...

Shaping the Dataset

Since kaggle does not have enough memory (16gb RAM), disk usage (73 GB) and GPU (13GB) to process the entire dataset, we will have to limit our model from 28441 to 700 lyrics. Kaggle give It's worth mentioning that this same test was performed locally and took approximately 100 hours to perform.

```
In [6]: # Dataframe shape to show how many columns and rows the dataframe have  
df.shape
```

```
Out[6]:  
(28441, 1)
```

```
In [7]: # Take first 700 rows  
df = df[:700]
```

```
In [8]: df.head()
```

```
Out[8]:
```

	Lyric
0	Hey, slow it down. What do you want from me. W...
1	Died last night in my dreams. Walking the stre...
2	I've paid my dues. Time after time. I've done ...
3	So I got my boots on,. Got the right amount of...
4	I wish that this night would never be over. Th...

```
In [9]: # Dataframe shape to show how many columns and rows the dataframe have a  
fter last cell  
df.shape
```

```
Out[9]:  
(700, 1)
```

Now, to get Statistical information, the next cell is going to calculate the number of words per row, this is going to help us to determine the Frequency Distribution of number of words for each text extracted

In [10]:

```
df['Number_of_words'] = df['Lyric'].apply(lambda x:len(str(x).split()))
df.head()
```

Out[10]:

	Lyric	Number_of_words
0	Hey, slow it down. What do you want from me. W...	314
1	Died last night in my dreams. Walking the stre...	224
2	I've paid my dues. Time after time. I've done ...	153
3	So I got my boots on,. Got the right amount of...	365
4	I wish that this night would never be over. Th...	295

Statistical information

In [11]:

```
df['Number_of_words'].describe()
```

Out[11]:

```
count    700.000000
mean     248.065714
std       97.323252
min       31.000000
25%      178.000000
50%      233.000000
75%      309.000000
max       589.000000
Name: Number_of_words, dtype: float64
```

- **count:** Number of rows to evaluate
- **mean:** Average of words per row in the dataset
- **std:** Word's standard deviation
- **min:** Minimum amount of words found in a lyric or row
- **max:** Maximum amount of words found.

In [12]:


```
import matplotlib.pyplot as plt
plt.style.use('ggplot')
plt.figure(figsize=(12,6))
sns.distplot(df['Number_of_words'],kde = False,color="red",bins=200)
plt.title("Frequency distribution of number of words for each text extr
acted", size=20)
```

```
/opt/conda/lib/python3.7/site-packages/seaborn/distributions.py:2557: FutureWarning: `distplot` is a deprecated function and will be removed in a future version. Please adapt your code to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).
```

```
warnings.warn(msg, FutureWarning)
```

Out[12]:

```
Text(0.5, 1.0, 'Frequency distribution of number of words for each text extracted')
```




- **Y axis:** Represent how many times a word was found in the dataset
- **X axis:** Represent the amount of different words found;

Tokenization

The data from the column named **Lyric** must be preprocessed and to achieve these, the words will have to be converted into numbers. This process is called "tokenization".

Keras uses the class **Tokenizer()** to do this job, this class has two important methods to be used:

- **_fit_on_text()** : Update the internal vocabulary based on a given list of texts or in this case, "Lyrics" column, where each entry of the list is going to be a token.
- **_texts_to_sequences()** : Transform each text within the list of texts supplied to a sequence of integers; only words known by the tokenizer will be considered.



```
In [13]: tokenizer = Tokenizer()
tokenizer.fit_on_texts(df['Lyric'].astype(str).str.lower())

total_words = len(tokenizer.word_index)+1
tokenized_sentences = tokenizer.texts_to_sequences(df['Lyric'].astype(str))
tokenized_sentences[0]
```

```
Out[13]: [128,
          338,
          9,
          48,
```

31,
33,
1,
45,
72,
6,
31,
33,
1,
45,
72,
6,
35,
13,
459,
31,
33,
1,
45,
72,
6,
31,
33,
1,
45,
72,
6,
75,
387,
50,
95,
7,
43,
2,
108,
88,
232,

70,
202,
368,
653,
7,
43,
2,
290,
88,
7,
1023,
23,
40,
80,
25,
52,
18,
31,
33,
1,
45,
72,
6,
31,
33,
1,
45,
72,
6,
28,
16,
88,
32,
13,
1073,
9,
49,

139,
16,
88,
10,
2,
92,
66,
1,
48,
9,
1878,
6,
32,
69,
7,
784,
4,
372,
28,
125,
204,
112,
128,
31,
33,
1,
45,
72,
6,
31,
33,
1,
45,
72,
6,
35,
26,

1074,
4,
61,
11,
47,
39,
379,
5,
26,
124,
193,
42,
1,
26,
6,
2456,
13,
7,
3010,
23,
2116,
22,
832,
6,
109,
39,
527,
9,
2117,
75,
387,
50,
95,
7,
43,
30,
2,

108,
66,
1,
506,
70,
2,
593,
198,
155,
23,
2,
82,
1,
85,
340,
8,
81,
28,
16,
88,
32,
13,
1073,
9,
49,
139,
16,
88,
10,
2,
92,
66,
1,
48,
9,
1878,
6,

32,
69,
7,
784,
4,
372,
28,
125,
204,
112,
128,
31,
33,
1,
45,
72,
6,
31,
33,
1,
45,
72,
6,
28,
16,
88,
32,
14,
6,
2,
92,
66,
1,
48,
34,
2,
92,

66,
1,
48,
18,
28,
16,
88,
32,
13,
1073,
9,
49,
139,
16,
88,
10,
2,
92,
66,
1,
48,
9,
1878,
6,
32,
69,
7,
784,
4,
372,
28,
125,
204,
112,
128,
31,
33,

1,
45,
72,
6,
28,
16,
88,
32,
13,
1073,
9,
49,
139,
16,
88,
10,
2,
92,
66,
1,
48,
9,
1878,
6,
32,
69,
7,
784,
4,
372,
28,
125,
204,
112,
128,
2118,
45,

```
72,  
6,  
2118,  
45,  
72,  
6,  
2118,  
45,  
72,  
6,  
2118,  
45,  
72,  
6]
```

Slash sequences into a n-gram sequence

After the text is tokenized, the words will be sorted to represent them numerically by creating an input sequence using the created tokens.

```
In [14]:  
input_sequences = list()  
for i in tokenized_sentences:  
    for t in range(1, len(i)):  
        n_gram_sequence = i[:t+1]  
        input_sequences.append(n_gram_sequence)
```

Padding

Before the model generation, is necessary to normalize all sentences to the same standard lenght, to avoid the memory overflow and to get the layers of the model way more deep, this is a simple process to add a 0's in the beginning of the text, resulting in layers of the same size.

_padsequences Transform a list of sequences that is a lists of integers into a 2D array, in this case the list is called input_sequences.

Sequences resulting shorter than **maxlen** are padded with 0's until they have the same length.

The position where the zeros will be added is determined by the argument **padding**, in this case, it will be done at the beginning of the sequence.

sequence before padding

```
[21, 4, 2, 12, 22, 23, 13, 2, 24, 6, 2, 7, 2, 4, 25],
[ 2, 26, 7, 27, 14, 9, 1, 4, 28 ],
[15, 25, 1, 29, 6, 15, 30],
[ 1, 16, 17, 27, 30, 1, 5, 2 ],
[31, 2, 28, 6, 32, 9, 33]
```



sequence after padding

(padding and truncate in front/pre)

```
[23, 13, 2, 24, 6, 2, 7, 2, 4, 25],
[ 0, 2, 26, 7, 27, 14, 9, 1, 4, 28],
[ 0, 0, 0, 15, 25, 1, 29, 6, 15, 30],
[ 0, 0, 1, 16, 17, 27, 30, 1, 5, 2],
[ 0, 0, 0, 31, 2, 28, 6, 32, 9, 33],
```

MAX_SEQUENCE_LENGTH = 10

In [15]:

```
max_sequence_len = max([len(x) for x in input_sequences])
input_sequences = np.array(pad_sequences(input_sequences, maxlen=max_sequence_len, padding='pre'))
```

In [16]:

```
input_sequences[:20]
```

Out[16]:


```
array([[ 0,  0,  0, ...,  0, 128, 338],
       [ 0,  0,  0, ..., 128, 338,  9],
       [ 0,  0,  0, ..., 338,  9, 48],
       ...,
       [ 0,  0,  0, ..., 35, 13, 459],
       [ 0,  0,  0, ..., 13, 459, 31],
       [ 0,  0,  0, ..., 459, 31, 33]], dtype=int32)
```

In [17]:

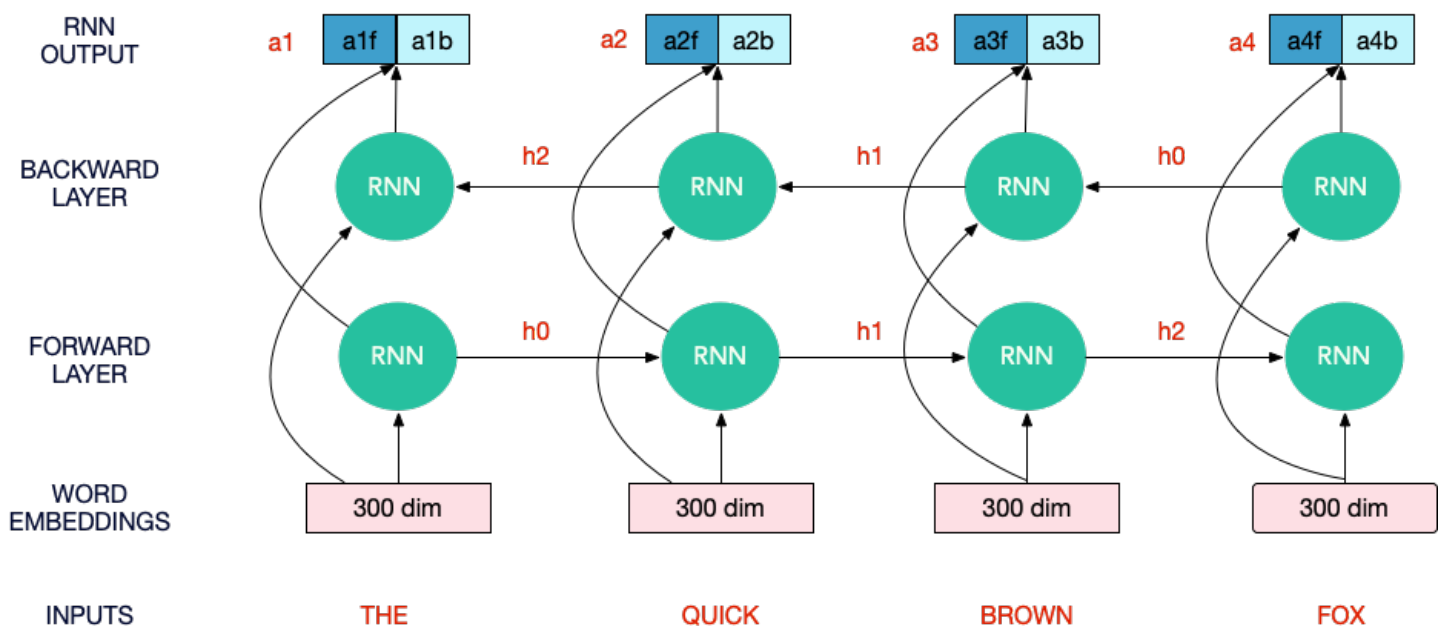
```
# create predictors and label
X, labels = input_sequences[:, :-1], input_sequences[:, -1]
y = tf.keras.utils.to_categorical(labels, num_classes=total_words)
```

Creating the Model

This test will use the Bidirectional LSTM model, this kind of neural networks run as the name says: in two ways. This is from past to future and vice versa, this is how the model preserves the information of both states at any point. LSTM neural networks are mostly used where context is involved.



Dimension of a_i = size of hidden state vector h
 In our code we define h dimension as 64



In []:

```
model = Sequential()
```

Models in Keras are defined as a sequence of layers, and the Sequential model is about adding layers one at a time. Layers are the basic building block of neural network.

Layers:

Embedding

- Is a core layer, can only be used as the first layer in a model, turns positive integers into dense vectors of fixed size (first parameter is the size of the vocabulary, second parameter is the dimension of the dense embedding, and third parameter is about the length of sequences which is required because we will use a Dense layer later)

```
In [ ]: model.add(Embedding(total_words, 40, input_length=max_sequence_len-1))
```

Bidirectional:

- Is a recurrent layer, a bidirectional wrapper for RNN's which will receive a layer as an input being LSTM layer the one we chose, it will receive a positive integer as it's input which refers to the amount of output nodes that should be returned.

```
In [ ]: model.add(Bidirectional(LSTM(250)))
```

Dropout:

- Is a regularization layer. This layer randomly sets input units to 0, with a frequency of the value we pass it, at each step during training time which helps prevent overfitting.

```
In [ ]: model.add(Dropout(0.1))
```

Dense:

- Is a core layer, and a densely-connected neural network layer. Receives as first parameter a positive integer which refers to the amount of output nodes that should be returned. Second parameter is the one named **activation** which defines the type of predictions the model can make; for the kind of problem we are abording the one which suits the better is softmax which outputs a vector of values (input) that can be interpreted as probabilities of being used.

In []:

```
model.add(Dense(total_words, activation='softmax'))
```

Compile method.

Takes two relevant parameters:

- **loss:** Also known as a cost function; works during the optimization process and it's role is to calculate the error of the model. Cross-entropy is used to estimate the difference between an esimated and predicted probability distributions. categorical_cross-entropy will be used because it's best suited for this kind of problems and is almost universally used to train deep learning neural networks due to the results it produces.
- **optimizer:** Is responsible for reducing the losses and to provide the most accurate results possible. Adam is the option chosen because is the best choice offered by Keras to train the neural network in less time and more efficiently. Earlystop will stop the training if the model has stopped improving, this will be checked at the end of every epoch.

Optimization algorithm and Performance metrics

The optimization algorithm added in the configuration layer will be **Adam**, because of the good performance and results in other projects it has.

In this case, the 'accuracy' will be measured as performance metric, which gives closeness of calculated value to the actual value.

```
In [ ]: model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
```

fit method trains the model for the fixed number of epochs given (iterations on the dataset).

```
In [ ]: earllystop = EarlyStopping(monitor='loss', min_delta=0, patience=3, verbose=0, mode='auto')
history = model.fit(X, y, epochs=20, verbose=1, callbacks=[earllystop])
```

Evaluating the Model

In this block a new graphic will be generated and displayed, the Y axis will stand for accuracy and X axis will stand for the amount of epochs; as shown, in order to increase the accuracy, you have to increase the number of epochs during the training.


```
In [ ]: # plot the accuracy

plt.plot(history.history['accuracy'], label='train acc')
plt.legend()
plt.show()
plt.savefig('AccVal_acc')
```

Import the Trained Model

Once the training process is completed it only remains the import of our model so we can test how does it work, in our case the trained model is called 'song_lyrics_generator'.

```
In [18]: import matplotlib.pyplot as plt
import seaborn as sns
from keras.models import load_model
model = load_model('../input/songlyricmodel/song_lyrics_generator.h5')
```

Function to Generate the song

This step is in charge of preparing the function that will be used to complete a song given the model previously trained, it will predict the next words based on the input words sumintrated as 'seed_text'. For this to work a tokenization must be applied to the seed_text, then a padding will be applied to the sequences generated and passed into the trained model so the next word can be predicted.

In [19]:

```
def complete_this_song(seed_text, next_words):
    for _ in range(next_words):
        token_list = tokenizer.texts_to_sequences([seed_text])[0]
        token_list = pad_sequences([token_list], maxlen=max_sequence_length-1, padding='pre')
        predicted = model.predict_classes(token_list, verbose=0)
        output_word = ""
        for word, index in tokenizer.word_index.items():
            if index == predicted:
                output_word = word
                break
        seed_text += " " + output_word
    return seed_text
```

Examples

In [20]:

```
complete_this_song("I am missing you", 200)
```

```
/opt/conda/lib/python3.7/site-packages/tensorflow/python/keras/engine/sequential.py:450: UserWarning: `model.predict_classes()` is deprecated and will be removed after 2021-01-01. Please use instead: * `np.argmax(model.predict(x), axis=-1)`, if your model does multi-class classification (e.g. if it uses a `softmax` last-layer activation). * `(model.predict(x) > 0.5).astype("int32")`, if your model does binary classification (e.g. if it uses a `sigmoid` last-layer activation).
warnings.warn("`model.predict_classes()` is deprecated and '
```

Out[20]:

```
"I am missing you i believe in the things you were so far away from me
i could not see the words that i was so cold and i never need to know y
our love is good i don't know how to tell you i'm not a fortune teller
i never change but i want you to stay i don't know what to tell you i'm
not a fortune teller i never change but i want you to stay i don't know
what to tell you i'm not a fortune teller i never change but i want you
to stay i don't know what to tell you i'm not a fortune teller i never
change but i want you to stay i don't know what to tell you i'm not a f
ortune teller i never change but i want you to stay i don't know what t
o tell you i'm not a fortune teller i never change but i want you to st
ay i don't know what to tell you i'm not a fortune teller i never chang
e but i want you to stay i don't know what to tell you i'm not a fortun
e teller i never change but i want you to"
```

In [21]:

```
complete_this_song("It's a cruel and random world", 80)
```

Out[21]:

```
"It's a cruel and random world is not much between how how could you do
and i see your life is a ghost and my heart is a ghost town my heart is
a ghost town my heart is a ghost town my heart is a ghost town my heart
is a ghost town my heart is a ghost town my heart is a ghost town my he
art is a ghost town my heart is a ghost town my heart is a ghost town m
y heart"
```

In [22]:

```
complete_this_song("I want a piece of pizza", 80)
```

Out[22]:

"I want a piece of pizza your eyes the bad are burning hot the sea you know you feel it up you are calling to you you look at me tonight you think of me of us how how how do how do we do how do we do how do we do how do we do how do we do how do we do how or now and now you couldn't see the ocean of hate your life you reply if"

In [23]:

```
complete_this_song("Love flowers", 80)
```

Out[23]:

"Love flowers get to her love and you make it okay but i'm not here i still still make you wanna be the one for you ooh oh oh oh oh baby baby baby baby baby baby baby baby you're gonna get you home and you go standing in your way and i don't want to miss a thing because i'm happy clap along if you know what happiness is is enough for me and you can do i know that"

In [24]:

```
complete_this_song("Hate flowers", 80)
```

Out[24]:

"Hate flowers love me love me love me how do you do you know what you do you love me if you love me if you love me love you don't want me to me and maybe i want you to trust me again i want to be your fantasy maybe i'm gonna be the one who understands you through me i know you understand me i want you to take me back to find to take to take you the sweetest"

Glosario.

- Acordes** Conjunto de notas musicales sonando al mismo tiempo.[1]. 35
- Aprende** Adquirir el conocimiento de algo por medio del estudio, análisis o de la experiencia.[1]. 23
- Armonia** Unión y combinación de sonidos simultáneos y diferentes, pero acordes.[1]. 34
- Estado** Situación en que se encuentra alguien o algo, y en especial cada uno de sus sucesivos modos de ser o estar.[1]. 37
- Estocástico** Que está sometido al azar y que es un objeto de análisis estadístico.[1]. 37
- Estrofa** Conjunto de versos que generalmente se ajustan a una medida y a un ritmo determinado y constante.[1]. 34
- Melodia** Es una sucesión lineal ordenada y coherente de sonidos musicales los cuales forman una unidad estructurada con un sentido musical, independiente del acompañamiento.
Sucesión de sonidos que por su manera de combinarse resulta agradable de oír.[2]. 34
- Máquinas de Estados Finitos** Conocidas también como Finite State Machines por su traducción en inglés, nos sirven para realizar procesos bien definidos en un tiempo discreto. Reciben una entrada, realizan un proceso y nos entregan una salida.[3]. 37
- Recurrente** Algo que vuelve a ocurrir o a aparecer después de un intervalo.[1]. 23
- Sistema** Conjunto de elementos con relaciones de interacción e interdependencia las cuales le confieren entidad propia al formar un todo unificado.[4]. 23, 37

Acrónimos.

- API** Application Programm Interface. 42, 94, 95
- AWS** Amazon Web Services. 6, 41–44, 53, 64, 81, 92
- BERT** Bidirectional Encoder Representations from Transformers. 1, 2, 4, 6, 26, 28–30, 32, 33, 46, 48, 56, 65, 87
- BPE** Byte Pair Encoding. 30, 33
- CLS** Classification. 29
- CSS** Cascading Style Sheet. 49
- DBMS** Sistema de gestión de base de datos. 33
- EC2** Elastic Compute Cloud. 41, 44, 51, 52, 93
- FQDN** Fully Qualified Domain Name. 40
- GCP** Google Cloud Platform. 6, 42–44
- GPT** Generative Pretrained Transformer. 4, 30–33
- GPU** Graphic Processor Unit. 41, 44
- HDD** Hard Drive Disk. 53, 54, 61, 62
- HTML** Hypertext Markup Language. 48, 49
- HTTP** Hypertext Transfer Protocol. 38, 53
- HTTPS** Hypertext Transfer Protocol Secure. 50
- JSON** Javascript Object Notation. 33

LTSM Long Short Term Memory. 2, 47, 55

MLM Modelado de Lenguaje Enmascarado. 28, 48

PLN Procesamiento del Lenguaje Natural. 25, 26, 28, 30, 33, 48

RNN Recurrent Neural Network. 55

S3 Simple Storage Service. 53

SDK Software Development Kit. 43

SEP Separate. 29

SQL Structured Query Language. 50

SSD Solid State Drive. 53, 54, 61

SSL Secure Socket Layer. 40, 50

SVG Scalable Vector Graphics. 49

TLS Transport Layer Security. 50

UI User Interface. 42

VPS Virtual Private Server. 38, 53

WIP Work In Progress. 15

XML Extensible Markup Language. 49

Bibliografía

- [1] Real Academia Española (2020, noviembre), Diccionario de la lengua española, [En línea]. Disponible: <https://dle.rae.es> [Último acceso: 10 de diciembre del 2020].
- [2] Oxford Lexico (2020, noviembre), Definitions, Meanings, Synonyms, and Grammar by Oxford, [En línea]. Disponible: <https://www.lexico.com> [Último acceso: 2 de diciembre del 2020].
- [3] J. A. Gutiérrez Orozco, Escuela Superior de Cómputo (2008, septiembre 15), Máquinas de Estados Finitos, [En línea]. Disponible: http://delta.cs.cinvestav.mx/~mcintosh/cellularautomata/Summer_Research_files/maquinasef.pdf [Último acceso: 15 de diciembre del 2020].
- [4] O. Jaramillo, Universidad Nacional Autónoma de México (2007, mayo 03), El concepto de Sistema, [En línea]. Disponible: <https://www.ier.unam.mx/ojs/pub/Termodinamica/node9.html> [Último acceso: 2 de diciembre del 2020].
- [5] Chaney, D. (2012). The Music Industry in the Digital Age: Consumer Participation in Value Creation. *International Journal of Arts Management*, (1), pp. 15.
- [6] Sutskever, I., Martens, J., Hinton, G. E. (2011, January). Generating text with recurrent neural networks. In *ICML*.
- [7] Kim, Y. (2014). Convolutional neural networks for sentence classification. *arXiv preprint arXiv:1408.5882*.
- [8] Monteith, K., Martinez, T. R., & Ventura, D. (2012, May). Automatic Generation of Melodic Accompaniments for Lyrics. In *ICCC*, pp. 87-94.
- [9] Nikolov, N. I., Malmi, E., Northcutt, C. G., Parisi, L. (2020). Conditional Rap Lyrics Generation with Denoising Autoencoders. *arXiv preprint arXiv:2004.03965*.

- [10] Baker, F. A. (2015). What about the music? Music therapists' perspectives on the role of music in the therapeutic songwriting process. *Psychology of Music*, 43(1), pp. 122-139.
- [11] Guerrero, J. (2012). El género musical en la música popular: algunos problemas para su caracterización. *Trans. Revista transcultural de música*, (16), pp. 1-22.
- [12] Wang, A., & Cho, K. (2019). Bert has a mouth, and it must speak: Bert as a markov random field language model. *arXiv preprint arXiv:1902.04094*.
- [13] Honnibal, M., & Montani, I. (2017). spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing.
- [14] V. Advani (2021, febrero 11), What is Artificial Intelligence? How does AI work, Types and Future of it?, [En línea]. Disponible: <https://www.mygreatlearning.com/blog/what-is-artificial-intelligence/> [Último acceso: 6 de abril del 2021].
- [15] IBM Corporation (2021, marzo 31), Artificial Intelligence (AI), [En línea]. Disponible: <https://www.ibm.com/cloud/learn/what-is-artificial-intelligence> [Último acceso: 6 de abril del 2021].
- [16] L. Hardesty (2017, abril), Explained: Neural networks, [En línea]. Disponible: <https://news.mit.edu/2017/explained-neural-networks-deep-learning-0414> [Último acceso: 15 de noviembre del 2020].
- [17] amBientech (2019, julio 30), ¿Qué es la neurona?, [En línea]. Disponible: <https://ambientech.org/la-neurona> [Último acceso: 6 de abril del 2021].
- [18] National Cancer Institute (2021), Neurons & Glial Cells, [En línea]. Disponible: <https://training.seer.cancer.gov/brain/tumors/anatomy/neurons.html> [Último acceso: 30 de abril del 2021].
- [19] C. Gershenson (2012, octubre), Artificial Neural Networks for Beginners, [En línea]. Disponible: <https://www.uv.mx/mia/files/2012/10/Artificial-Neural-Networks-for-Beginners.pdf> [Último acceso: 6 de abril del 2021].
- [20] Rubik's Code (2018, febrero), How do Artificial Neural Networks learn?, [En línea]. Disponible: <https://rubikscodene.net/2018/01/15/how-artificial-neural-networks-learn/> [Último acceso: 7 de abril del 2021].

- [21] S. Leijnen, F. van Veen (2020, mayo), The Neural Network Zoo, [En línea]. Disponible: https://www.researchgate.net/publication/341373030_The_Neural_Network_Zoo [Último acceso: 20 de noviembre del 2020].
- [22] IBM Cloud Education (2020, septiembre 14), What are Recurrent Neural Networks?, [En línea]. Disponible: <https://www.ibm.com/cloud/learn/recurrent-neural-networks> [Último acceso: 26 de marzo del 2021].
- [23] ref IBM Cloud Education (2020, julio 2), Natural Language Processing [En línea]. Disponible: <https://www.ibm.com/cloud/learn/natural-language-processing> [Último acceso: 20 de abril del 2021].
- [24] ref A. Vaca (2020, mayo), Transformers en Procesamiento del Lenguaje Natural, [En línea]. Disponible: <https://www.iic.uam.es/innovacion/transformers-en-procesamiento-del-lenguaje-natural/> [Último acceso: 15 de abril del 2021].
- [25] ref A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. Gomez, L. Kaiser & I. Polosukhin (2017, diciembre), Attention Is All You Need, [En línea]. Disponible: <https://arxiv.org/pdf/1706.03762.pdf> [Último acceso: 15 de abril del 2021].
- [26] ref J. Devlin, M. Chang, K. Lee, K. Toutanova (2019, mayo), BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, [En línea]. Disponible: <https://arxiv.org/pdf/1810.04805.pdf> [Último acceso: 11 de abril del 2021].
- [27] ref R. Horev (2018, noviembre), BERT Explained: State of the art language model for NLP, [En línea]. Disponible: <https://towardsdatascience.com/bert-explained-state-of-the-art-language-model-for-nlp-f8b21a9b6270> [Último acceso: 11 de abril del 2021].
- [28] ref B. Lutkevich (2020, enero), BERT language model, [En línea]. Disponible: <https://searchenterpriseai.techtarget.com/definition/BERT-language-model> [Último acceso: 12 de abril del 2021].
- [29] ref A. Radford, J. Wu, D. Amodei, D. Amodei, J. Clark, M. Brundage & I. Sutskever (2020, enero), Better Language Models and Their Implications, [En línea]. Disponible: <https://openai.com/blog/better-language-models/> [Último acceso: 14 de abril del 2021].

- [30] ref M. Edward (2019, febrero), Too powerful NLP model (GPT-2), [En línea]. Disponible: <https://towardsdatascience.com/too-powerful-nlp-model-generative-pre-training-2-4cc6afb6655> [Último acceso: 14 de abril del 2021].
- [31] ref A. Radford, K. Narasimhan, T. Salimans & I. Sutskever (2018), Improving Language Understanding by Generative Pre-Training, [En línea]. Disponible: https://s3-us-west-2.amazonaws.com/openai-assets/research-covers/language-unsupervised/language_understanding_paper.pdf [Último acceso: 14 de abril del 2021].
- [32] ref J. Montantes(2019, mayo), Examining the Transformer Architecture, [En línea]. Disponible: <https://towardsdatascience.com/examining-the-transformer-architecture-part-1-the-openai-gpt-2-controversy-feceda4363bb> [Último acceso: 14 de abril del 2021].
- [33] ref J. Vig(2019, marzo), GPT-2: Understanding Language Generation through Visualization, [En línea]. Disponible: <https://towardsdatascience.com/openai-gpt-2-understanding-language-generation-through-visualization-8252f683b2f8> [Último acceso: 14 de abril del 2021].
- [34] Oracle México (2020, noviembre), ¿Qué es una base de datos?, [En línea]. Disponible: <https://www.oracle.com/mx/database/what-is-database/> [Último acceso: 20 de noviembre del 2020].
- [35] Escribir Canciones (2008), Estructura y elementos de una canción, [En línea]. Disponible: <https://dle.rae.es> [Último acceso: 2 de diciembre del 2020].
- [36] Swing this Music (2008), ¿QUÉ SECCIONES PUEDE TENER UNA CANCIÓN?española, [En línea]. Disponible: <https://sites.google.com/site/swingthismusiccast/interpretacio/estructura-cancion/secciones-de-una-cancion> [Último acceso: 2 de diciembre del 2020].
- [37] J. R. Norris (1997), Markov Chains, [En línea]. Disponible: <https://cape.fcfm.buap.mx/jdzf/cursos/procesos/libros/norris.pdf> [Último acceso: 15 de diciembre del 2020].
- [38] NGINX (2016, mayo 17), What is NGINX?, [En línea]. Disponible: <https://www.nginx.com/resources/glossary/nginx/> [Último acceso: 27 de mayo del 2021].

- [39] Mozilla.org (2021, febrero 19), HTML basics, [En línea]. Disponible: https://developer.mozilla.org/en-US/docs/Learn/Getting_started_with_the_web/HTML_basics [Último acceso: 15 de mayo del 2021].
- [40] Mozilla.org (2021, mayo 14), HTML5, [En línea]. Disponible: <https://developer.mozilla.org/es/docs/Web/Guide/HTML/HTML5> [Último acceso: 15 de mayo del 2021].
- [41] W3C (2016), HTML & CSS, [En línea]. Disponible: [Último acceso: 15 de mayo del 2021].
- [42] Mozilla.org (2021, abril 27), What is JavaScript?, [En línea]. Disponible: https://developer.mozilla.org/en-US/docs/Learn/JavaScript/First_steps/What_is_JavaScript [Último acceso: 15 de mayo del 2021].
- [43] OpenSSL (2018), OpenSSL, [En línea]. Disponible: <https://www.openssl.org> [Último acceso: 15 de mayo del 2021].
- [44] Documentation Group. (n.d.). Welcome! - The Apache HTTP Server Project. Apache. Retrieved April 6, 2021, from <https://httpd.apache.org/>
- [45] G., D. (2021, March 9). What is Apache? An In-Depth Overview of Apache Web Server. Hostinger Tutorials. <https://www.hostinger.com/tutorials/what-is-apache>
- [46] What is a web server? - Learn web development — MDN. (2021, January 27). MDN Web Docs. https://developer.mozilla.org/en-US/docs/Learn/Common_questions/What_is_a_web_server
- [47] What is SSL? (2017, May 15). SSLSHOPPER. <https://www.sslshopper.com/what-is-ssl.html>
- [48] Verisign. (2015, August 30). ¿Qué es un certificado SSL? – Verisign. Verisign NameStudio. https://www.verisign.com/es_LA/website-presence/online/ssl-certificates/index.xhtml
- [49] Bavati, I. (2020, September 22). Data Science in the Cloud - Towards Data Science. Medium. <https://towardsdatascience.com/data-science-in-the-cloud-239b795a5792> (September 2020)

- [50] G. (2021, March 5). Comparing Google Cloud Platform, AWS and Azure - Georgian Impact Blog. Medium. <https://medium.com/georgian-impact-blog/comparing-google-cloud-platform-aws-and-azure-d4a52a3adbd2>
- [51] I., A. (2015, October 2). Jupyter/IPython Notebook Quick Start Guide. Jupyter Notebook Beginner Guide. https://jupyter-notebook-beginner-guide.readthedocs.io/en/latest/what_is_jupyter.html
- [52] Jones, E. (2021, March 25). Google Cloud vs AWS in 2021 (Comparing the Giants). Kinsta. <https://kinsta.com/blog/google-cloud-vs-aws/>
- [53] Copyright.gov (2021), Copyright in General, [En línea]. Disponible: <https://www.copyright.gov/help/faq/faq-general.html#what> [Último acceso: 04 de mayo del 2021].
- [54] World Intellectual Property Organization (2007), THE ARTS AND COPYRIGHT, [En línea]. Disponible: https://www.wipo.int/edocs/pubdocs/en/copyright/935/wipo_pub_935.pdf [Último acceso: 04 de mayo del 2021].
- [55] CÁMARA DE DIPUTADOS DEL H. CONGRESO DE LA UNIÓN (2014, julio 14), LEY FEDERAL DEL DERECHO DE AUTOR, [En línea]. Disponible: https://www.ucol.mx/content/cms/13/file/federal/LEY_FED_DEL_DERECHO_DEL_AUTOR.pdf [Último acceso: 05 de mayo del 2021].
- [56] Aaron Tay (2021, Abril 23), Data Cleaning Techniques [En línea]. Disponible: <https://www.digitalvidya.com/blog/data-cleaning-techniques/> [Último acceso: 30 Mayo 2021]
- [57] Python (2021), What is Python? Executive Summary, [En línea]. Disponible: <https://www.python.org/doc/essays/blurb/> [Último acceso: 24 de abril del 2021].
- [58] MongoDB. (2019), ¿Qué es MongoDB?, [En línea]. Disponible: <https://www.mongodb.com/es>. [Último acceso: 26 Marzo 2021].
- [59] Noteworthy Programming Masterpiece (2019), openssl-nodejs [En línea]. Disponible: <https://www.npmjs.com/package/openssl-nodejs> [Último acceso: 26 Marzo 2021]
- [60] The Apache Software Foundation (2019), Apache Tomcat [En línea]. Disponible: <http://tomcat.apache.org/index.html> [Último acceso: 26 Marzo 2021]

- [61] OneLook Dictionary Search (2016), Privacy Policy [En línea]. Disponible: <https://www.onelook.com/about.shtml> [Último acceso: 19 Mayo 2021]
- [62] MongoDB Inc (2018), MongoDB Licensing [En línea]. Disponible: <https://www.mongodb.com/community/licensing> [Último acceso: 19 Mayo 2021]
- [63] Google Research: BERT (2018), LICENSE [En línea]. Disponible: <https://github.com/google-research/bert/blob/master/LICENSE> [Último acceso: 19 Mayo 2021]
- [64] Apache (2004), The Apache License, Version 2.0 [En línea]. Disponible: <https://httpd.apache.org/docs/current/license.html> [Último acceso: 19 Mayo 2021]
- [65] Facebook: React (2018), LICENSE [En línea]. Disponible: <https://github.com/facebook/react/blob/master/LICENSE> [Último acceso: 19 Mayo 2021]
- [66] Python (2001), History and License [En línea]. Disponible: <https://docs.python.org/3/license.html> [Último acceso: 19 Mayo 2021]
- [67] Elastic (2021), Elastic License 2.0 [En línea]. Disponible: <https://www.elastic.co/es/licensing/elastic-license> [Último acceso: 19 Mayo 2021]
- [68] Google Cloud Platform (2021), Descripción general de Google Cloud [En línea]. Disponible: <https://cloud.google.com/docs/overview> [Último acceso: 25 Mayo 2021]
- [69] Amazon Web Services (2021), Informática en la nube con AWS [En línea]. Disponible: <https://aws.amazon.com/es/what-is-aws/> [Último acceso: 25 Mayo 2021]
- [70] Azure (2021), Conozca Azure [En línea]. Disponible: <https://azure.microsoft.com/es-mx/overview/> [Último acceso: 25 Mayo 2021]
- [71] ITM Platform (2010), Matriz de Evaluación de Riesgos [En línea]. Disponible: <https://www.itmplatform.com/es/recursos/matriz-de-evaluacion-de-riesgos/#RiskSetId=rh25q/6IQWFCFvYIwSUF6A==> [Último acceso: 26 Mayo 2021]

- [72] Kaggle (2019, Noviembre 17), Song lyrics from 6 musical genres [En línea]. Disponible: <https://www.kaggle.com/neisse/scrapped-lyrics-from-6-genres> [Último acceso: 25 Mayo 2021]
- [73] Kaggle (2010), How to Use Kaggle [En línea]. Disponible: <https://www.kaggle.com/docs/datasets> [Último acceso: 25 Mayo 2021]
- [74] Google (2018, Septiembre 5), Dataset Search [En línea]. Disponible: <https://datasetsearch.research.google.com> [Último acceso: 25 Mayo 2021]
- [75] Amazon, Open Data on AWS [En línea]. Disponible: <https://aws.amazon.com/es/opendata/?wwps-cards.sort-by=item.additionalFields.sortDate&wwps-cards.sort-order=desc> [Último acceso: 25 Mayo 2021]
- [76] Music4All (2020), A New Music Database and Its Applications [En línea]. Disponible: <https://sites.google.com/view/contact4music4all> [Último acceso: 25 Mayo 2021]
- [77] Vagalume (2002), Vagalume: Music e tudo [En línea]. Disponible: <https://www.vagalume.com.br/> [Último acceso: 25 Mayo 2021]
- [78] TopTenAI (2020, Mayo 9), Top 10 Lyric Generator Review 2021 [En línea]. Disponible: <https://topten.ai/lyric-generator-review/> [Último acceso: 30 Mayo 2021]
- [79] Kingma, D. P., Ba, J. (2014). Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980.
- [80] Sanjeevi, M. (2018, June 21). Chapter 10.1: DeepNLP — LSTM (Long Short Term Memory) Networks with Math. Medium. <https://medium.com/deep-math-machine-learning-ai/chapter-10-1-deepnlp-lstm-long-short-term-memory-networks-with-math-21477f8e4235>
- [81] Foote, K. D. (2019, June 17). A Brief History of Natural Language Processing (NLP). DATAVERSITY. <https://www.dataversity.net/a-brief-history-of-natural-language-processing-nlp/>
- [82] Amazon (2021), Amazon EC2 [En línea]. Disponible: <https://aws.amazon.com/es/ec2/?ec2-whats-new.sort-by=item.additionalFields.postDateTime&ec2-whats-new.sort-order=desc> [Último acceso: 1 Junio 2021]

- [83] Amazon (2021), Amazon SageMaker [En línea]. Disponible: <https://aws.amazon.com/es/sagemaker/> [Último acceso: 1 Junio 2021]
- [84] Amazon (2021), Amazon S3 [En línea]. Disponible: <https://aws.amazon.com/es/s3/> [Último acceso: 1 Junio 2021]
- [85] Bansal, S. (2018, May 27). Language Modelling and Text Generation using LSTMs — Deep Learning for NLP. Medium. <https://medium.com/@shivambansal36/language-modelling-text-generation-using-lstms-deep-learning-for-nlp-ed36b224b275>